

中国科学院大学

University of Chinese Academy of Sciences

硕士学位论文

面向恶意加密流量检测的对抗样本攻击技术研究

作者姓名：孙汉武

指导教师：朱宇佳 高级工程师

中国科学院信息工程研究所

学位类别：工学硕士

学科专业：网络空间安全

培养单位：中国科学院信息工程研究所

2023 年 6 月

Research on Adversarial Example Attack Technology for Malicious Encrypted Traffic Detection

A thesis submitted to

University of Chinese Academy of Sciences

in partial fulfillment of the requirement

for the degree of

Master of Science in Engineering

in Cyberspace Security

By

Sun Hanwu

Supervisor: Zhu Yujia

Institute of Information Engineering, Chinese Academy of Sciences

June, 2023

中国科学院大学
学位论文原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究工作所取得的成果。承诺除文中已经注明引用的内容外，本论文不包含任何其他个人或集体享有著作权的研究成果，未在以往任何学位申请中全部或部分提交。对本论文所涉及的研究工作做出贡献的其他个人或集体，均已在文中以明确方式标明或致谢。本人完全意识到本声明的法律结果由本人承担。

作者签名:

日　　期:

中国科学院大学
学位论文授权使用声明

本人完全了解并同意遵守中国科学院大学有关收集、保存和使用学位论文的规定，即中国科学院大学有权按照学术研究公开原则和保护知识产权的原则，保留并向国家指定或中国科学院指定机构送交学位论文的电子版和印刷版文件，且电子版与印刷版内容应完全相同，允许该论文被检索、查阅和借阅，公布本学位论文的全部或部分内容，可以采用扫描、影印、缩印等复制手段以及其他法律许可的方式保存、汇编本学位论文。

涉密及延迟公开的学位论文在解密或延迟期后适用本声明。

作者签名:　　导师签名:

日　　期:　　日　　期:

摘 要

为应对加密流量的爆炸式增长，机器学习算法被广泛应用于恶意加密流量检测领域。但是机器学习算法易受对抗样本的攻击，对抗样本是一种经过精心设计的恶意样本，会导致目标模型以高置信度输出错误的分类结果。

虽然已经有一些对抗样本攻击工作被提出用以评估和提升这些检测模型的鲁棒性，但是它们仍然存在一些不足。首先现有恶意加密流量检测模型在面对对抗样本攻击时的脆弱性分析工作不完善。其次假设攻击者能够本地运行目标模型是不普适的（白盒假设），即使一些基于生成对抗网络的灰盒工作仍然需要目标模型给出反馈。最后大部分现有工作都是在特征空间生成对抗样本，难以转化为有实际攻击意义的对抗性流量。

为更好的分析在对抗样本攻击场景下基于机器学习的恶意加密流量检测模型的脆弱性，并进一步提升其鲁棒性，本文基于流量空间提出一种更加具有实用性的黑盒对抗样本攻击方法。本文的主要贡献如下:

第一，针对现有恶意加密流量检测模型在面对对抗样本攻击时的脆弱性分析工作不完善的问题，本文通过实验评估此类模型所使用特征及算法在面对对抗样本攻击时的脆弱性。通过实验评估流量特征的重要性、对抗显著性、扰动难易度和目标算法的鲁棒性，为对抗样本攻击时的特征选择和目标模型选择提供指导。

第二，针对现有白盒对抗样本攻击方法假设不普适的问题，本文提出基于对抗样本可转移性的黑盒对抗样本攻击方法。通过训练出与目标模型拥有相似决策边界的代理模型来产生可转移的对抗样本。实验证明了本方法生成的对抗样本对于 LSTM 和 FS-Net 有超过 96.2% 的检测逃逸率，对于 SVM、LR 和 DNN 等模型也有超过 50.5% 的检测逃逸率。

第三，针对现有对抗样本攻击方法大多停留在特征层面的问题，本文提出了基于流量扰动的对抗性流量翻译方法。分别提出流量包长扰动算法和流量时间扰动算法将包长相关和时间相关的对抗性特征翻译成对抗性流量。实验证明了本文所提方法在更加实际的场景下生成的对抗样本能够取得 82.1% 的检测逃逸率，比目前最先进的黑盒对抗样本攻击方法高 29.9%。

关键词：对抗样本攻击，黑盒攻击，机器学习，恶意加密流量检测，流量扰动

Abstract

Machine learning algorithms have been widely leveraged in traffic classification tasks to overcome the challenges brought by the enormous encrypted traffic. On the contrary, ML-based classifiers are vulnerable to adversarial example attacks, which can fool the classifiers into giving wrong outputs with elaborately designed examples.

Some adversarial attacks have been proposed to evaluate and improve the robustness of ML-based traffic classifiers, but there are some shortcomings. Firstly, existing works have poorly evaluated the vulnerability of the traffic features and the robustness of ML-based traffic detection models in an adversarial example attack setting. Secondly, it is not universal for these attacks to assume that the adversary can run the target classifiers locally(white-box assumption). Even some GAN-based grey-box attacks still require the target classifiers to act as discriminators. Finally, most of the existing works generate adversarial examples in the feature space, which is difficult to be translated into meaningful adversarial traffic.

Hence, a more practical black-box adversarial attack was proposed in this paper to evaluate and improve the robustness of ML-based encrypted traffic classifiers. The main contributions are as follows:

1. To address the problem of imperfect vulnerability analysis of existing ML-based malicious traffic classifiers in adversarial example attack settings, we evaluated the features and algorithms used in these classifiers. By evaluating the importance, attack effectiveness, perturbation difficulty of traffic features and robustness of algorithms, we provided guidance for feature selection and target selection in an adversarial traffic attack scenario.

2. To address the problem that the assumptions of existing white-box adversarial example attacks are universal, we propose a black-box adversarial example attack based on the transferability of adversarial examples. The transferable adversarial examples are generated by a proxy model with similar decision boundaries as the target model. Rich and complete experiments prove that the adversarial examples generated by our method have an evasion detection rate(EDR) of more than 96.2% for LSTM and FS-Net, and more than 50.5% EDR for SVM, LR and DNN.

3. To address the problem that most existing adversarial attacks stay in the feature space, we propose an adversarial traffic translation method based on traffic perturbation. Our method proposes the traffic packet length perturbation algorithm and the traffic time perturbation algorithm for translating packet length-dependent and time-dependent features into adversarial traffic, respectively. The experiments result shows that our method achieves an evasion detection rate of 82.1% in a more practical scenario, which

is higher than the state-of-the-art black-box adversarial attack by 29.9%.

Key Words: Adversarial Example Attack, Black-box Attack, Machine Learning, Malicious Encrypted Traffic Detection, Traffic Perturbation

目 录

第 1 章 绪论 ····· 1
1.1 研究背景及研究意义 ····· 1
1.2 国内外研究现状 ····· 3
1.2.1 恶意流量检测技术的发展 ····· 4
1.2.2 对抗样本技术的发展 ····· 4
1.2.3 对抗样本技术在恶意加密流量检测领域的应用 ····· 7
1.3 研究内容 ····· 8
1.4 论文结构 ····· 9
第 2 章 相关技术概述 ····· 11
2.1 基于机器学习的恶意流量检测模型 ····· 11
2.1.1 机器学习模型 ····· 11
2.1.2 恶意流量检测模型 ····· 12
2.2 对抗样本攻击 ····· 13
2.2.1 对抗样本攻击概述 ····· 13
2.2.2 对抗样本与生成对抗网络的区别 ····· 14
2.3 机器学习模型的评估指标 ····· 15
第 3 章 恶意加密流量检测模型脆弱性分析 ····· 17
3.1 引言 ····· 17
3.2 实验设置 ····· 17
3.2.1 数据集介绍 ····· 17
3.2.2 恶意加密流量检测模型介绍 ····· 18
3.2.3 对抗样本攻击方法介绍 ····· 19
3.2.4 特征提取 ····· 19
3.3 特征重要性评估 ····· 21
3.3.1 信息增益 ····· 21
3.3.2 基尼指数 ····· 21
3.4 特征对抗显著性评估 ····· 24
3.4.1 对抗性显著图的概念 ····· 24
3.4.2 计算对抗性显著图 ····· 24
3.5 特征扰动难易度评估 ····· 26

3.6 特征评估结果汇总 ····· 27
3.7 目标算法鲁棒性评估 ····· 29
3.8 本章小结 ····· 30
第 4 章 基于对抗样本可转移性的黑盒对抗攻击方法 ····· 31
4.1 引言 ····· 31
4.2 问题背景 ····· 31
4.2.1 白盒假设与黑盒假设 ····· 31
4.2.2 对抗样本攻击的理论解释 ····· 32
4.2.3 对抗样本的可转移性 ····· 33
4.3 问题提出与方法动机 ····· 33
4.3.1 威胁模型 ····· 33
4.3.2 黑盒对抗样本攻击遇到的困难 ····· 34
4.3.3 方法动机 ····· 34
4.4 方法阐述 ····· 36
4.4.1 代理模型构建 ····· 37
4.4.2 对抗样本生成 ····· 38
4.5 实验评估 ····· 38
4.5.1 对抗性扰动幅度限制 ϵ 的影响 ····· 39
4.5.2 代理模型训练集数量的影响 ····· 39
4.5.3 代理模型架构的影响 ····· 41
4.5.4 目标模型使用特征类型的影响 ····· 42
4.5.5 对抗样本攻击有效性 ····· 42
4.6 本章小结 ····· 43
第 5 章 基于流量扰动的对抗性流量翻译方法 ····· 45
5.1 引言 ····· 45
5.2 问题背景 ····· 45
5.2.1 特征空间与流量空间 ····· 45
5.2.2 基于流量空间的对抗样本攻击方法的特殊性 ····· 46
5.3 问题定义 ····· 47
5.3.1 威胁模型 ····· 47
5.3.2 流量翻译过程中遇到的困难 ····· 48
5.4 方法阐述 ····· 49
5.4.1 流量特征分类 ····· 49
5.4.2 流量包长扰动算法 ····· 49

5.4.3 流量时间扰动算法 ····· 51
5.5 实验评估 ····· 51
5.5.1 对比实验 ····· 51
5.5.2 对比实验结果 ····· 52
5.6 对抗性流量可视化 ····· 52
5.6.1 对抗样本有效性 ····· 52
5.6.2 对抗样本的可转移性 ····· 53
5.7 本章小结 ····· 54
第 6 章 总结与展望 ····· 55
6.1 总结 ····· 55
6.2 展望 ····· 56
参考文献 ····· 57
致谢 ····· 61
作者简历及攻读学位期间发表的学术论文与其他相关学术成果 · 63

图目录

图 1-1 Google 应用加密流量占比 ····· 1
图 1-2 基于图像的对抗样本攻击示意图 ····· 2
图 1-3 针对恶意加密流量检测模型的对抗样本攻击场景示意图 ····· 3
图 1-4 本文研究内容 ····· 9
图 2-1 深度神经网络示意图 ····· 12
图 2-2 生成对抗网络示意图 ····· 15
图 3-1 信息增益 (a) CICIDS2017 数据集 (b) MTA 数据集 ····· 22
图 3-2 基尼指数 (a) CICIDS2017 数据集 (b) MTA 数据集 ····· 23
图 3-3 统计特征对抗性显著图（在 CICIDS2017 数据集上实验） ····· 25
图 3-4 序列特征对抗性显著图 (在 MTA 数据集上实验） ····· 26
图 3-5 特征评估结果汇总 ····· 28
图 4-1 白盒对抗样本攻击决策边界模型 ····· 32
图 4-2 黑盒对抗样本攻击场景 ····· 34
图 4-3 黑盒对抗样本攻击遇到的困难 ····· 35
图 4-4 黑盒对抗样本攻击决策边界模型 ····· 36
图 4-5 黑盒对抗样本攻击框架 ····· 36
图 4-6 对抗样本绕过率 (EDR) 随扰动幅度 (ϵ) 变化 (a) 展示不同的恶意软件家族 (b) 展示不同的目标模型 ····· 40
图 4-7 对抗样本检测逃逸率随着训练样本数量的变化 ····· 40
图 5-1 基于机器学习的恶意流量检测模型数据流向 ····· 46
图 5-2 基于特征空间与流量空间的对抗样本攻击 ····· 46
图 5-3 图片数据与流量数据对比 ····· 47
图 5-4 基于流量空间的对抗样本攻击 ····· 48
图 5-5 对抗样本攻击有效性 ····· 53
图 5-6 对抗样本可转移性 ····· 53

表目录

表 1-1 恶意流量检测的技术发展 ····· 5
表 1-2 白盒对抗样本攻击技术总结 ····· 6
表 1-3 黑盒对抗样本攻击技术总结 ····· 7
表 1-4 对抗样本技术在恶意加密流量检测模型上的应用 ····· 8

表 2-1 二分类结果混淆矩阵 ····· 15
表 3-1 数据集信息总结 ····· 18
表 3-2 流量特征表 ····· 20
表 3-3 特征分类贡献度评估 ····· 24
表 3-4 特征提取复杂度 ····· 27
表 3-5 鲁棒性评估实验结果 ····· 29
表 4-1 对抗样本决策边界模型总结 ····· 33
表 4-2 对抗样本在不同架构模型之间的可转移性 ····· 41
表 4-3 目标模型检测性能及对抗样本检测逃逸率 ····· 43
表 5-1 特征总结 ····· 49
表 5-2 对比实验结果 ($\psi_p = \mathrm{DNN}, \epsilon = 0.1$) ····· 52
表 5-3 流量样本 X_i 分类混淆矩阵 ····· 54

符号列表

字符

Symbol	Description
$\mathbb{T}$	Traffic set
T_{adv}	Adversarial traffic
$\mathbb{X}$	Traffic features set
$X_{m/b}$	A malicious/benign flow in $\mathbb{X}$
$X_{adv/c}$	A adversarial/clean flow in $\mathbb{X}$
x^i	The i-th feature of flow $\mathbb{X}$
$Y_{m/b}$	Actual malicious/benign label
$Z_{m/b}$	Prediction of target classifiers
$A_{m/b}$	Prediction of proxy classifiers
ψ_t	Target classifier
ψ_p	Proxy classifier
θ	Parameters of a classifier
ρ	Adversarial perturbation
$\mathcal{L}$	Loss function
ϵ	Perturbation constraint

算子

Symbol	Description
∇	gradient operator
$\oplus$	append

缩写

DPI	Deep Packet Inspection
QoS	Quality of Service
GRU	Gated Recurrent Unit
FGSM	Fast Gradient Sign Method
BIM	Basic Iterative Method
BA	Boundary Attack
AoA	Attack on Attention

PSO	Particle Swarm Optimization
ML	Machine Learning
SVM	Support Vector Machine
DNN	Deep Neural Network
RNN	Recurrent Neural Network
DL	Deep Learning
GAN	Generative Adversarial Networks
P	Precision
R	Recall
EDR	Evasion Detection Rate
FNR	False Negative Rate
LR	Logistic Regression
DT	Decision Tree
IF	Isolation Forest
LSTM	Long Short-Term Memory
IG	Information Gain
GI	Gini Index
MTA	Malware Traffic Analysis

第 1 章　绪论

1.1　研究背景及研究意义

随着人们对个人隐私与网络安全的逐渐重视，越来越多的网站和应用采用加密技术来保护其传输的数据。截至 2023 年 5 月 7 日，95% 的谷歌应用流量都是经过加密的[1]（如图 1-1 ）。虽然加密技术有效的保护了用户的个人隐私和数据安全，但是也有越来越多的恶意软件使用加密技术来逃避检测。据思科报告，截至 2020 年超过 70% 的恶意软件使用加密技术来规避审查，并且有超过 60% 的组织无法有效解密恶意加密流量[2]。

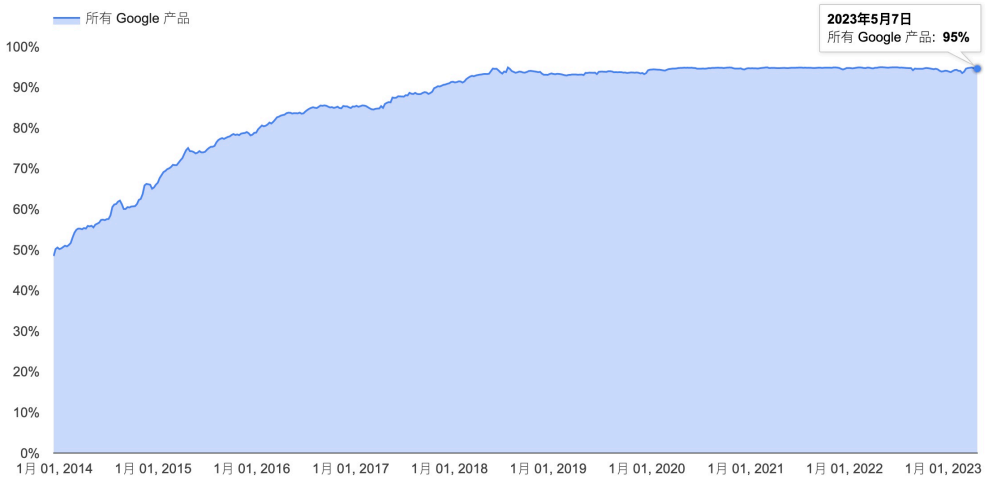


图 1-1 Google 应用加密流量占比

Figure 1-1 Percentage of encrypted traffic for Google Apps

恶意流量经过加密后其应用层数据不再可见，这就意味着传统的基于深度包检测（Deep Packet Inspection, DPI）[3,4] 的方法不再适用; 而基于规则的检测模型只能够对已经发现的威胁进行检测，而不能够检测未知威胁[5,6]。但是随着近年来的网络攻击越来越复杂，基于统计的检测模型无法应对如此复杂的攻击[7]。为了应对这些挑战，基于机器学习或深度学习算法的检测模型被广泛应用于流量分类领域并逐渐成为主流技术。这些应用包括服务质量（Quality of Service, QoS）[8]、应用分类[9] 和恶意流量检测等[10–12]。

虽然基于机器学习的恶意加密流量检测模型展现出强大的检测能力，但是机器学习算法本身却引入了一种全新的攻击面————对抗样本攻击[13,14]。对抗样本是在普通数据样本上添加微小但是精确的对抗性扰动所形成的，能够使目标检测模型以非常高的置信度输出一个错误的分类结果。如图 1-2 所示，Goodfellow 等[14] 通过对熊猫图片施加微小的对抗性扰动，成功的误导分类模型以 99.3% 的置信度输出分类结果为长臂猿。为了验证对抗样本攻击的存在并提高基于机器学习的分类系统在面对对抗样本攻击时的鲁棒性，计算机视觉社区提

出了许多对抗样本生成方法，例如 FGSM[14]、DeepFool[15]、C&W[16] 和 One Pixel Attack[17]。使用这些方法生成的对抗样本都能够有效地大幅度降低包括 GoogLeNet[18]、VGG16[19] 等在内的经典图像分类系统的分类准确率。但是由于计算机视觉领域和流量领域所处理的数据不同，这些针对计算机图像分类器所设计的攻击方法并不能直接用于攻击加密流量分类器。因为网络流量数据需要满足复杂的 TCP/IP 协议簇的规范，并不是任何字节都可以随意扰动。此外，从网络流量数据中提取特征的过程是不可逆，这给针对流量分类器的对抗样本攻击方法带来了巨大的挑战。

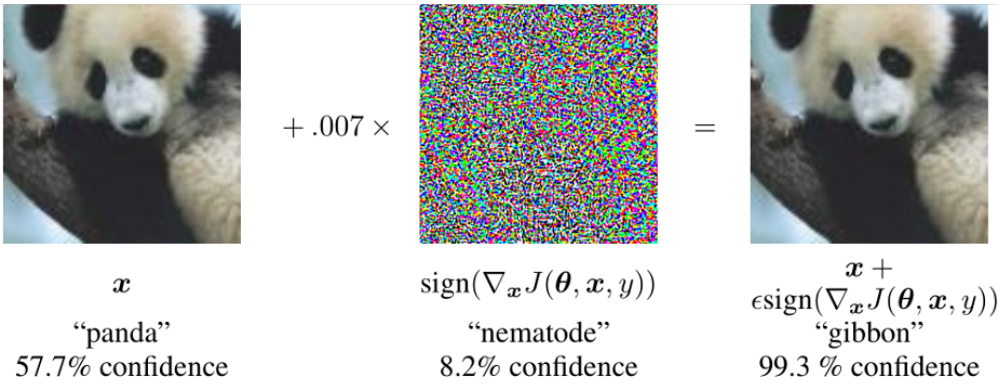


图 1-2 基于图像的对抗样本攻击示意图

Figure 1-2 Schematic diagram of image-based adversarial example attack

虽然已经存在一些工作尝试去解决这些由于数据的差异性带来的挑战并设计出针对恶意加密流量检测模型的对抗样本攻击方法[20–22]，但是这些工作中都或多或少的存在一些问题，导致这些工作很难应用于实际工作中。首先，在如图 1-3 所示的恶意加密流量检测场景中，大多数现有针对恶意加密流量分类器的对抗样本攻击工作都是基于白盒假设的，即假设攻击者能够获取目标模型的完整信息，包括目标模型的架构、超参数甚至目标模型的副本文件，但是现实生活中攻击者很难获取到这些信息。即使一些基于灰盒假设的工作声称不需要目标模型副本进行反向传播[23] 计算梯度，但是仍然需要目标模型的输出作为反馈用于指导生成对抗性扰动。其次，部分现有工作直接去修改目标模型的特征向量（特征空间），而不是扰动原始的网络流量（流量空间）。这虽然能够有效的解决加密流量分类器在提取流量特征阶段不可逆的问题，但是忽略了现实情况下攻击者很难去直接操作目标模型特征向量的问题。

综上所述，基于机器学习的恶意加密流量检测模型虽然展现出强大的检测能力，但是同时也引入了一种名为对抗样本的新漏洞。为了验证这种漏洞的存在并提高现有恶意加密流量分类器的鲁棒性，许多研究者提出了针对这些恶意加密流量分类器的对抗样本攻击方法，但是现有的攻击方法存在一些不实际的假设，难以实际应用在现实场景中。因此，基于更加合理的假设，提出一种实用性的对抗样本攻击方法来验证恶意加密流量在现实生活中的鲁棒性是一个值得研究的方向。本课题围绕恶意加密流量检测领域，针对现有对抗样本攻击方法存在

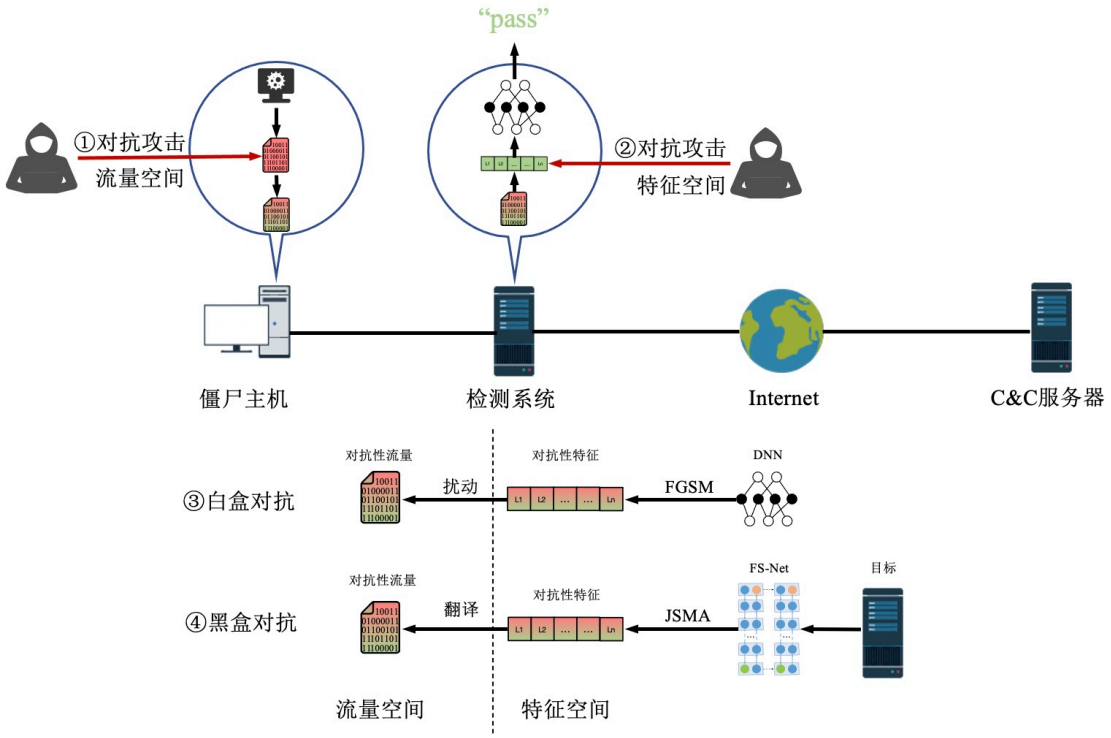


图 1-3 针对恶意加密流量检测模型的对抗样本攻击场景示意图

Figure 1-3 Adversarial attack scenario against a malicious traffic detection model

的局限性，基于更加合理的假设提出适用于恶意加密流量检测模型的对抗样本攻击方法。

本研究的意义在于以下三点。第一，充分评估并分析现有基于机器学习的恶意加密流量检测模型在面对对抗样本攻击时的脆弱性。第二，深入研究对抗样本的攻击原理，为对抗样本攻击找到合适的理论模型。第三，对抗样本攻击技术的研究是防御性工作的基础，能够促进恶意加密流量检测领域的对抗性防御工作的进步。

1.2　国内外研究现状

流量检测是一个自从计算机网络诞生之初就已经产生的课题，延续至今已经产生了多种多类的检测技术，近年来随着加密流量的盛行，机器学习技术被广泛应用在加密流量检测领域。对抗样本攻击技术是计算机视觉社区提出的一种针对机器学习算法的攻击技术，通过在特定方向上扰动机器学习算法模型的输入，改变机器学习模型的输出结果，从而达到攻击的目的。对抗样本攻击技术随之也引起了恶意加密流量检测社区的关注，但是由于网络流量数据的特殊性，直接将经典的对抗样本攻击方法作用于恶意加密流量检测模型效果并不理想，近年来也有越来越多的研究者提出适用于恶意加密流量检测领域的对抗样本攻击技术。下面将详细介绍恶意加密流量检测、对抗样本攻击和针对恶意加密流量检测的对抗样本攻击这三个领域的国内外研究现状。

1.2.1 恶意流量检测技术的发展

在非加密流量还大行其道的时，最原始的恶意流量检测方式就是 DPI，通过匹配预定义的流量字段的方式进行检测，例如网络地址、端口、域名等常见字段，或者由专家提取的恶意流量特有的协议字段，也有从应用层数据中提取的关键字等。例如著名的开源入侵检测引擎 Snort[4] 就是将流量中特定字段的值与数据库进行对比，从而检测出恶意流量。基于黑名单匹配的检测方法虽然简单高效，但是十分容易被绕过，并且无法检测一些新出现的私有协议流量或者被加密过的流量。为了避免被绕过，并且能够检测私有协议流量和加密协议流量，研究者提出了基于统计特征签名的检测方法。例如 Marchette[5] 和 Crotti 等[6] 通过提取已知恶意流量的统计特征并形成签名库的形式进行检测。基于统计特征签名的检测方法虽然在一定程度上增大了绕过难度，但是仍然不适合复杂攻击场景的检测，并且无法检测未知的攻击场景。

随着机器学习技术的兴起，越来越多的研究者开始利用机器学习强大的数据分析能力进行恶意加密流量检测。早期的研究者通过特征工程的方式从流量中提取出一组统计特征向量，将特征向量输入给机器学习模型，利用机器学习模型强大的数据分析能力将异常流量从常规流量中识别出来。例如 Sun 等[24] 首先从 TLS 流量中提取出一组特征，形成特征向量后提供给贝叶斯分类模型用于异常检测。Liu 等[25] 基于流量包级别的统计特征提出半监督学习方法用于进行加密流量分类。Anderson 等[26] 使用逻辑回归算法处理流量流级别的特征来检测恶意加密流量。这种方法虽然能够检测一些较为复杂的场景，但是其检测准确度十分依赖所提取的特征。

最新端到端的检测模型则直接使用深度学习算法处理原始的序列数据，利用深度学习强大的特征表示能力，自动从流量的序列特征中提取出特征向量，省去了人工提取特征的繁重工作。例如 MaMPF[27] 使用马尔科夫链对消息类型序列和长度块序列进行建模，计算每条流属于不同应用的概率。FS-Net[28] 则直接将流量的包长序列输入到一个由门控循环单元（Gated Recurrent Unit, GRU）[29] 组成的 Auto-Encoder[30] 中，将繁杂的特征提取工作交给 Auto-Encoder 完成，而分类器则使用简单的单层前馈神经网络，达到了非常不错的效果。

表 1-1 简要总结了恶意流量检测技术的发展历程。

1.2.2 对抗样本技术的发展

对抗样本本质上是深度神经网络存在的一种漏洞，围绕对抗样本的研究大致分为两个方面：对抗样本攻击技术和对抗样本防御技术。对于对抗样本攻击技术来说，按照攻击者是否需要目标模型的详细架构和参数划分又分为白盒攻击和黑盒攻击，所谓白盒攻击指的是攻击者可以完全获取目标模型的结构等关键信息，而黑盒攻击指的是攻击者对目标模型的细节完全不了解。下面将重点介绍对抗样本攻击技术的发展过程。

白盒对抗样本攻击技术。Szegedy 等[13] 第一次提出对抗样本的概念: 对输入

表 1-1 恶意流量检测的技术发展

Table 1-1 Technical development of malicious traffic detection.

流量类型	方法	基本原理	优势	劣势	代表性工作
非加密流量	深度包检测	匹配预定义的恶意流量字段	简单高效	无法处理加密流量; 易绕过	Snort[4] DPI[3]
	统计特征匹配	匹配预定义的恶意流量统计特征	简单高效 相对不易绕过	无法检测未知恶意流量	Marchette[5] Crotti 等[6]
加密流量	机器学习（统计特征）	提取恶意流量特征向量使用机器学习算法检测	能处理复杂攻击场景	需要人工设计特征向量	Sun 等[24] Liu 等[25] Anderson 等[26]
	机器学习（序列特征）	使用深度学习直接分析原始流量数据	不需要人工设计特征	易受对抗样本攻击	MaMPF[27] FS-Net[28]

给目标模型的样本恶意添加一些人无法察觉的、细微的干扰，诱导模型以非常高的高置信度输出一个错误的输出。论文中给出了一种原始的对抗样本生成方法，优化目标是在扰动最小的情况下，使目标分类器对加上了对抗性扰动后的样本给出错误的分类结果。求解这个问题是困难的，所以使用盒式限制进行转换，优化目标如公式 L-BFGS (1-1) 所示。

$$\min_{\boldsymbol{\rho}} c|\boldsymbol{\rho}| + \mathcal{L}\left(\mathbf{X}_c + \boldsymbol{\rho}, \ell\right) \text{ s.t. } \mathbf{X}_c + \boldsymbol{\rho} \in [0,1]^m \tag{1-1}$$

L-BFGS 方法生成对抗样本的效率不高，因此 Goodfellow 等[14] 提出了快速梯度符号方法（Fast Gradient Sign Method, FGSM）用于快速高效生成对抗样本，计算方法如公式 1-2 所示。

$$\mathrm{X}_{adv} = \mathrm{X} + \alpha \cdot \operatorname{sign}\left(\nabla_{\mathrm{X}} \mathcal{L}(\mathrm{X}, \mathrm{Y})\right) \tag{1-2}$$

上述两种方法在生成对抗性扰动时均只进行一次计算，没有迭代的过程，寻找出的最优解均比较粗略，为了解决这个问题，Kurakin 等[31] 提出了基本迭代方法（Basic Iterative Method, BIM）（迭代公式如 1-3 所示）。BIM 在 FGSM 的基础上加入了梯度剪裁和迭代计算的过程，找出的对抗样本更加精确。

$$\mathbf{X}_{adv}^{i+1} = \operatorname{Clip}_{\epsilon}\left\{\mathbf{X}_{adv}^{i} + \alpha \operatorname{sign}\left(\nabla \mathcal{L}\left(\boldsymbol{\theta}, \mathbf{X}_{adv}^{i}, Y\right)\right)\right\} \tag{1-3}$$

DeepFool[15] 也采用迭代的方式生成对抗样本，不仅能够实现比 FGSM 更小的扰动，重要在于提出了决策边界的分析方式，计算方法公式如 1-4 所示。

$$\mathbf{X}_{adv}^{i+1} \leftarrow \mathbf{X}_{adv}^{i} - \frac{f\left(\mathbf{X}_{adv}^{i}\right)}{\left\|\nabla f\left(\mathbf{X}_{adv}\right)\right\|_2^2} \nabla f\left(\mathbf{X}_{adv}^{i}\right) \tag{1-4}$$

上述方法计算对抗样本的扰动方向都是目标模型损失对输入样本所求梯度的方向，但是 Papernot 等[32] 提出的 JSMA 方法以输出类别置信度的梯度作为扰动的方向，同时将这个梯度称为前向梯度，通过选择前向梯度中对目标类别置信度增益最高的特征进行扰动。JSMA 的计算公式如 3.4 节中所示。

防御蒸馏算法[33] 的提出成功的抵挡了这些白盒对抗样本的攻击，于是 Carlini 等[16] 提出 C&W 方法来应对防御性蒸馏算法，C&W 算法使用了与 L-BFGS 不同的距离度量方式，并且使用了特殊的损失函数代替分类器原本的损失函数，计算方法如公式 1-5 所示。

$$\begin{aligned} &\min \|\rho\|_p + c \cdot f\left(\mathbf{X}_c + \rho\right) \\ &\text{s.t. } \mathbf{X} + \rho \in [0,1]^n \end{aligned} \tag{1-5}$$

白盒对抗样本攻击技术的发展如表 1-2 所示。

表 1-2 白盒对抗样本攻击技术总结

Table 1-2 Summary of white-box adversarial example attacks

方法	描述
L-BFGS[13]	首次提出对抗样本的概念，但是生成对抗样本的效率过低
FGSM[14]	能够快速产生对抗样本，但是只计算一次就生成对抗样本，最优解不精确
BIM[31]	最优解经过多次迭代和梯度剪裁生成
DeepFool[15]	实现比 FGSM 更微小的扰动，提出决策边界的分析方法
JSMA[32]	计算样本的前向导数，选择对提升目标类别置信度增益最大的特征进行扰动
C&W[16]	能够成功攻击对抗性蒸馏算法，使用特殊的距离度量方式和损失函数

黑盒对抗样本攻击技术。白盒攻击能够实施的前提是假设攻击者能够在本地运行目标模型的副本，通过目标模型的反向传播计算出对抗扰动，将对抗性扰动施加在普通样本上从而生成对抗样本。但是这种假设并不合理，因为大多数情况下攻击者无法获取目标模型的详细架构、参数信息及副本。基于此情况研究者提出了对抗样本的黑盒攻击技术。Chen 等[34] 提出基于替代模型的黑盒攻击方法 ZOO。替代模型是指利用类似分布的数据集，或者利用多次输入样本到目标模型中得到输出的结果，训练一个新的模型，并在新的模型上进行反向传播，进而得到对抗样本。Brendel 等[35] 提出基于决策边界的边界攻击 BA（Boundary Attack, BA）方法，边界攻击沿着对抗图像和非对抗图像之间的边界执行拒绝采样，通过多次迭代的方式使得条件逐渐收敛。为了在不同深度神经网络中都能够有比较好的结果，Chen 等[36] 等人提出了 AoA（Attack on Attention, AoA）攻击, AoA 想要将注意力热力图中的注意力从原始类别（非目标类别）转移到目标类别。黑盒对抗样本攻击技术的发展如表 1-3 所示。

表 1-3 黑盒对抗样本攻击技术总结

Table 1-3 Summary of black-box adversarial sample attack techniques

方法	描述
ZOO[34]	利用目标模型收集一批数据集用于训练与目标模型相似的替代模型，针对替代模型生成对抗样本
BA[35]	沿着对抗图像和非对抗图像之间的边界执行拒绝采样，通过多次迭代的方式使得条件逐渐收敛
AoA[36]	将注意力热力图中的注意力从原始类别（非目标类别）转移到目标类别

1.2.3　对抗样本技术在恶意加密流量检测领域的应用

虽然对抗样本技术的发展起源于计算机视觉领域，但是对抗样本揭示的是深度神经网络背后存在的漏洞，任何使用了机器学习算法的应用都存在这种漏洞。在网络安全领域，包括恶意加密流量检测系统在内的大量应用使用了机器学习算法以应对日益复杂的网络攻击。因此任何使用了深度学习算法的安全应用都会面临对抗样本攻击的风险。尽管对抗样本技术在恶意加密流量检测领域的起步较晚，但是目前已经存在一些工作，下面将详细介绍对抗样本技术在恶意加密流量检测领域的应用。

早期针对非加密流量的入侵检测系统的逃避攻击已经得到广泛研究。Kreibich 等[37] 通过引入流量规范器（Traffic Normalizer）的方式尝试模糊恶意攻击流量的规则以绕过入侵检测系统检测。Cheng 等[38] 尝试使用数据包拆分、有效负载突变等流量混淆方式以应对基于统计特征的入侵检测系统。虽然这些方法可以成功逃避早期的入侵检测系统，但是无法应对学习能力更强的基于深度学习的入侵检测系统。并且从严格意义上说这些绕过方法并不属于对抗样本攻击，因为它们利用的并不是深度神经网络的对抗样本漏洞。

最早利用对抗样本技术绕过恶意加密流量检测的研究只是简单的在特征向量上进行扰动，属于特征空间层次的攻击。Yang 等[39] 使用 L-BFGS 算法生成对抗样本攻击使用 AutoEncoder 的恶意加密流量检测模型，但是操作的样本是输入 AutoEncoder 的特征向量，而不是原始流量数据。Lin 等[20] 提出 IDSGAN，对基于传统机器学习算法和基于深度学习算法的恶意加密流量检测模型进行广泛的攻击验证，虽然 GAN 的性质使攻击属于黑盒攻击，但是生成对抗样本操作的空间仍然是特征向量而不是原始流量数据。流量空间层次的对抗样本攻击研究难以应用到实际攻击场景中，因为实际攻击场景中黑客无法直接修改目标检测系统中的特征向量。

为了解决这个问题，许多工作提出基于流量空间的对抗样本攻击。Hashemi 等[21] 尝试通过拆分、延迟和注入等方式操作流量以生成对抗样本用于攻击入侵检测系统，但是此方法仍然假设攻击者可以获取目标模型的详细细节，仍属于白盒攻击。Han 等[22] 分两步生成对抗样本，首先使用 GAN 生成特征向量空间的

对抗样本，然后通过粒子群优化算法（Particle Swarm Optimization, PSO）[40] 算法修改恶意加密流量使恶意加密流量经过特征提取器（Feature Extractor）后的特征向量达到要求。

对抗样本技术在恶意加密流量检测领域的发展如 1-4 所示。早期针对恶意加密流量检测系统的绕过攻击并没有利用机器学习的对抗样本漏洞，并不属于对抗样本攻击。真正属于对抗样本攻击的工作整体上呈现出两种发展趋势，一种由白盒攻击逐渐转向黑盒攻击；另一种则是由特征空间的攻击转向流量空间的攻击。

表 1-4 对抗样本技术在恶意加密流量检测模型上的应用

Table 1-4 Adversarial attacks for malicious encrypted traffic classifier

方法	流量混淆	对抗样本攻击	黑盒攻击	流量空间
Kreibich 等[37]	✓			
Cheng 等[38]	✓			
Yang 等[39]		✓		
IDSGAN[39]		✓	✓	
Hashemi 等[21]		✓		✓
Han 等[22]		✓	✓	✓

1.3 研究内容

对抗样本攻击给应用了机器学习算法的恶意加密流量检测模型带来了极大的安全挑战，然而针对对抗样本的研究却仍然处于起步阶段。特别是在恶意加密流量检测领域，大量的检测模型在设计之初并未考虑会遭受对抗样本攻击，也没有系统性地评估模型在遭受对抗样本攻击时的鲁棒性。同时，现有针对恶意加密流量检测模型的对抗样本攻击工作借鉴了计算机视觉社区的工作，但是由于图像和计算机网络流量数据存在本质的不同，导致现有这些工作存在两个方面的不足，一方面现有工作基于白盒或者灰盒的假设在一定程度上并不实际；另一方面现有工作直接生成的对抗样本是检测模型的中间产物，而并不是原始的计算机流量。本研究基于当前研究的现状和不足，提出了如图 1-4 所示的三点研究内容。

针对现有基于机器学习的恶意加密流量检测模型面对对抗样本攻击时的脆弱性分析工作不完善的问题，本文对现有恶意加密流量使用的流量特征和算法在面对对抗样本攻击时的脆弱性进行了全面的评估。针对现有恶意加密流量检测模型广泛使用的统计特征，本文使用信息增益和基尼指数两种方法来评估每个特征的重要性；其次使用对抗性特征显著图评估了统计特征和序列特征的对抗有效性，实验显示统计特征对抗有效性较高的特征与重要性较高的特征比较

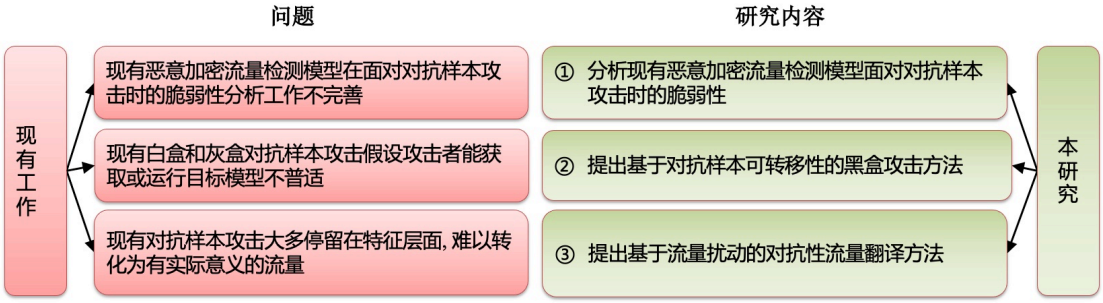


图 1-4 本文研究内容

Figure 1-4 The research content of this thesis

重合，而序列特征对抗有效性的特征都集中在序列特征的末尾，针对特征的评估工作对于之后对抗样本攻击时的特征选择具有一定的指导意义。针对不同的恶意加密流量检测模型，本文选取了三种基于神经网络的模型和五种传统机器学习模型作为目标模型进行评估，实验结果显示大部分恶意加密流量检测模型在面对对抗样本攻击时的鲁棒性较差。

针对现有白盒和灰盒对抗样本攻击假设不普适的问题，本文提出基于对抗样本可转移性的黑盒对抗样本攻击方法。本文提出了用于解释对抗样本攻击理论的决策边界模型，从理论上提出了成功实现对抗样本攻击的三个关键因素。基于决策边界模型提出了黑盒对抗样本攻击方法，通过实验证明了代理模型架构、代理模型训练数据、目标模型特征、对抗样本扰动幅度是影响对抗样本可转移性的四个关键因素。最后在最佳的实验设置下，通过实验证实了本方法对于未知模型的攻击有效性。

针对现有对抗样本攻击大多停留在特征层面的问题，本文提出基于流量扰动的对抗性流量翻译方法，将对抗性特征向量翻译为对抗性流量。对于包长特征，方法提出流量包长扰动算法，使用包填充和包插入的方式修改流量包长相关特征；对于时间特征，方法提出流量时间扰动算法，通过缓冲延迟发送的方式，修改每个数据包的发包时间。最后进行大量的对比实验用于对比本方法与目前最先进的白盒与黑盒方法，证明本方法的先进性。

1.4　论文结构

本文的组织结构如下：

第一章：绪论。本章首先详细阐述了本文的研究背景及研究意义——对抗样本攻击的出现给基于机器学习算法的恶意加密流量检测模型的鲁棒性带来了严峻的挑战。其次分别介绍了恶意加密流量检测模型、对抗样本攻击等相关领域的国内外研究现状。最后简要概述了本文的研究内容以及本文的行文结构。

第二章: 相关技术概述。本章首先介绍机器学习的一般模型，并且介绍其在恶意加密流量检测领域的具体应用。其次介绍了对抗样本攻击的基本原理，以及如何在恶意加密流量检测领域应用对抗样本攻击。最后给出了本文中使用到的

一些评估指标。

第三章：恶意加密流量检测模型脆弱性分析。本章首先给出了本文的实验设置，包括数据集、流量特征、目标模型等；其次评估了流量特征的对于分类的重要性以及对抗显著性；最后对基于机器学习算法的恶意加密流量检测模型进行黑盒对抗样本攻击，以评估他们的面对对抗样本攻击时的脆弱性。

第四章：基于对抗样本可转移性的黑盒对抗攻击方法。本章首先给出了解释对抗样本可转移性的决策边界理论；根据决策边界理论提出使用与目标模型决策边界相近的代理模型生成对抗样本；通过大量的实验探究了影响对抗样本可转移性的几个关键因素；最后通过的大量的实验验证了本文所提方法的有效性。

第五章：基于流量扰动的对抗性流量翻译方法。本章针对不同的流量特征提出了两种不同的流量扰动方法，针对包长特征提出流量包长扰动算法，针对时间特征提出流量时间扰动算法。基于两种流量扰动算法将对抗性特征序列翻译成对抗性流量。最后通过实验与目前最先进的白盒与黑盒方法进行对比，用以验证本方法的先进性。

第六章：总结与展望。本章主要总结了本文所提出的两个方法，并讨论了这些方法的局限性以及未来改进的方向。

第 2 章　相关技术概述

2.1　基于机器学习的恶意流量检测模型

2.1.1　机器学习模型

机器学习（Machine Learning, ML）通常是指一类让计算机程序从数据中学习到某种规律的算法。通常称提供给机器学习模型寻找规律的数据为样本，在典型的监督学习场景中，一条样本 (X, Y) 由一个包含多维特征的特征向量 $X = [x^1, x^2, ..., x^n]^T$ 和一个监督信号 Y 组成，众多的样本构成了训练机器学习模型的训练集 $\mathcal{D}$。

$$\mathcal{D} = \{X_1, X_2, ..., X_N\} \tag{2-1}$$

如果从生成式模型的角度理解机器学习，对于任何一个数据集，都可以看做是从某一个未知的数据分布 $\mathcal{N}(\theta)$ 中生成的，而机器学习算法模型 $\psi(X \sim \mathcal{N}(\theta); \hat{\theta})$ 的目标就是尽量去找到这个未知的数据分布，具体而言就是在训练数据的指导下，寻找和未知数均分布的参数相同或者相似的参数 $\hat{\theta}$，而使用的最优参数的模型 ψ' 在遇到训练集中没有出现的数据的时，能给出和目标数据分布相似的结果。

不同的机器学习模型，例如支持向量机（Support Vector Machine, SVM）[41]、深度神经网络（Deep Neural Network, DNN）[42] 或循环神经网络（Recurrent Neural Network, RNN）[43] 等，本质上是提供一个不同的参数搜索范围，越复杂的模型参数搜索的范围越大，越有可能包含目标参数。而训练的过程，就是在训练数据的指导下，一步步的迭代寻找最优的参数 θ'，最优参数可能并不直接等于目标参数，但是一定是所提供的参数范围内最接近目标参数的。

为了衡量参数 θ 优劣，需要用到训练数据中的监督信号，通过设计好的损失函数 $\mathcal{L}$ 将训练数据的标签 y 与在该组参数下的模型下的输出 $\hat{y}$ 进行对比，输出一个可以比较的 loss 值。通过不断的减少 loss 值，就可以逐步的寻找最优的参数。所以机器学习的训练过程实际上是一个最优化的过程，在给定的参数范围内找到最优的一组参数。具体的优化目标如公式 2-2 所示。

$$\theta^* = \arg\min_{\theta} \mathcal{L}(Y, \psi(X \sim \mathcal{D}, \theta)) \tag{2-2}$$

深度学习（Deep Learning, DL）特指一类由深度神经网络（Deep Neural Network, DNN）构成的机器学习模型。如图 2-1 所示，一个深度神经网络通常由输入层、隐藏层和输出层构成，其中隐藏层可能包含多个非线性层。对于给定的输入样本 x，深度神经网络的计算方式如公式 2-3 所示，理论上可以证明任意连续函数都可以通过只包含一层隐含层的深度神经网络实现。

$$f(X) = f_n\left(f_{n-1}\left(\cdots f_1(X)\right)\right)\cdots) \tag{2-3}$$

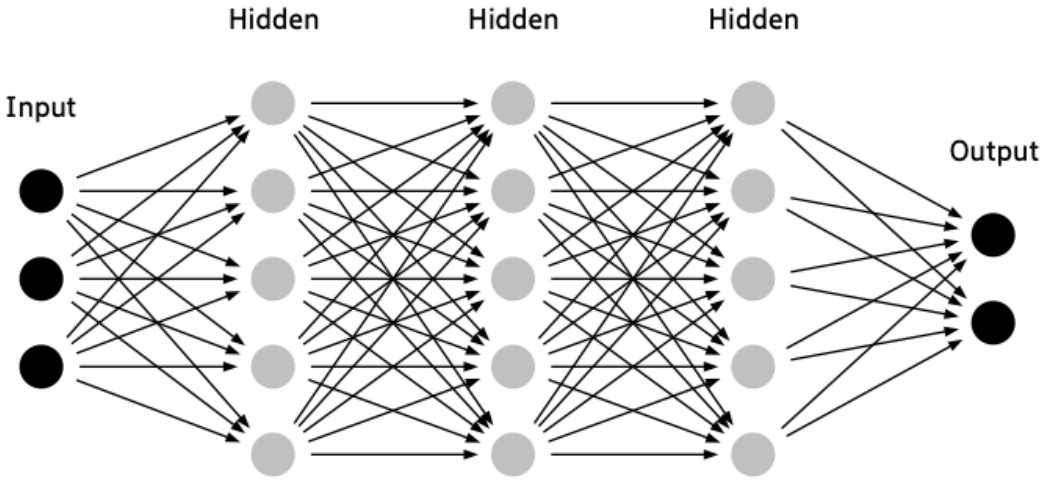


图 2-1 深度神经网络示意图

Figure 2-1 Schematic diagram of a deep neural network

2.1.2 恶意流量检测模型

在第一章中介绍到，恶意流量检测领域经过多年的发展，包含了众多的不同的模型，本文主要聚焦基于机器学习算法的恶意流量检测模型。对于基于机器学习的恶意流量检测模型，一般分为两个步骤，分别是流量预处理和算法检测。

计算机网络流量是一种非结构化的数据，所以在输入到机器学习模型之前必须要经过预处理过程。经过预处理的步骤，将原始的网络流量 $\boldsymbol{T}$ 处理成格式化的特征向量 $\boldsymbol{X} = [x^1, x^2, ..., x^N]$。现有的恶意流量检测工作中特征向量 $\boldsymbol{X}$ 的提取分为两种。一种是人工设计每个特征，这些特征可以是具体某个协议的字段，例如 TCP 的端口，DNS 的域名等；也可以是某个统计特征值，例如平均包大小等。经过人工设计的每维特征组成的特征向量就代表了原始的流量样本，而为了尽可能的保留更多的原始信息，这个特征向量维度比较高，部分模型甚至超过了 100 维。另一种特征提取方式为了尽量减少人工提取特征带来的偏差，选择直接输入原始流量序列信息。例如直接输入流量的前 N 个字节作为特征向量，或者输入一条流的包长序列作为特征向量等。利用深度学习强大的特征表示能力从这些序列信息中提取有价值的特征向量，最后用于分类。流量检测与其他的机器学习应用最大的不同之处在于数据的特殊性，由于计算机网络协议众多，产生的计算机流量数据不仅数量众多，而且种类繁杂，因此从标准的计算机流量中提取出具有分类价值的特征向量是一个十分耗时且繁杂的工作，并且提取的特征向量很大程度上会影响最终模型的检测准确率。

$$C(Y_{b/m}, \hat{Y}) = -\frac{1}{N}\sum_{i}^{N}\sum_{c=1}^{C} I(\hat{Y}^i = Y_c^i)\log \hat{Y}^i \tag{2-4}$$

当流量数据被处理成格式化的特征向量之后，就可以开始使用机器学习算

法进行分类工作了。恶意流量检测问题本质上属于一个二分类的问题，即对于任何一条待检测的计算机流量样本 X，需要找到一个映射函数 f，将其映射到良性和恶性这两个类别中，$f(x) \rightarrow Y_{b/m}$，这里的 Y_b 和 Y_m 分别表示良性和恶性的类别，只是这里的映射函数 f 都是机器学习算法。并且对于分类问题，使用的损失函数更多的是交叉熵函数 C(如公式 2-4)，而函数 $I(\hat{Y} = Y_c^i)$ 在 $\hat{Y}$ 和监督信号 Y_c^i 相等的时输出 1，否则输出 0。直观的理解交叉熵函数的意义就是如果映射函数的输出 $\hat{Y}$ 与目标类别 Y_c 相同的话，累加计算 $\hat{Y}^i$ 的对数值。并且当 $\hat{Y}^i$ 越接近 1，即映射函数的分类结果与标签结果越接近的时 loss 越小。此时，基于机器学习的恶意流量检测模型的优化目标如公式 2-5 所示。

$$\theta^* = \arg\min_{\theta} C(Y_{b/m}, f(x \sim \mathcal{D}, \theta)) \tag{2-5}$$

2.2　对抗样本攻击

2.2.1　对抗样本攻击概述

对抗样本是一种经过恶意扰动的训练样本，在普通的训练样本上施加对抗性扰动 ρ 从而生成对抗样本 $X_{adv} = X + \rho$，这种具有指向性的恶意样本会导致目标函数 ψ 给出错误的分类结果，如果攻击者希望目标模型输出特定的类别，则称为有目标的对抗样本攻击，否则称为无目标的对抗样本攻击，如公式 2-6 所示。

$$\begin{cases} \psi(X + \rho) \neq \psi(X) \\ \psi(X + \rho) = Y_{target} \end{cases} \tag{2-6}$$

对抗性扰动的生成是通过一个最优化的过程完成，即计算出使目标函数达到最大值或者最小值的对抗性扰动。一般情况下生成对抗样本时的目标函数 $\mathcal{L}_{adv}$ 如公式 2-7 所示。即希望目标模型对 X_{adv} 给出的分类结果 $\hat{Y} = \psi(X_{adv}; \theta^*)$ 尽量远离其真实类别 Y_{true}，并且尽可能接近目标类别 Y_{target}。

$$\mathcal{L}_{adv}(X_{adv}, Y_{target}, Y_{true}; \theta^*) = -C(\psi(X_{adv}; \theta^*), Y_{true}) + C(\psi(X_{adv}; \theta^*), Y_{target}) \tag{2-7}$$

生成对抗样本的优化目标如公式 2-8 所示。

$$X_{adv}^* = \arg\min_{X} \mathcal{L}_{adv}(X, Y_{target}, Y_{true}; \theta^*) \tag{2-8}$$

但是这个优化目标存在一个问题，如果无限制的添加扰动，哪怕扰动没有任何对抗性，只是普通的随机噪声，只要幅度足够大的情况下，都可以达到干扰函数分类结果的目的。因此需要控制对抗性扰动的幅度，甚至从某种意义上说，只有在一定幅度内的对抗性扰动才具有实际意义，因为扰动程度过大的话样本数据就失去了原本的属性。衡量扰动程度的方法有很多，本文使用切比雪夫距离来度量对抗性扰动的幅度，如公式 2-9 所示。

$$d(\rho) = ||X_{adv} - X||_{\infty} \tag{2-9}$$

因此，生成对抗样本的优化目标如 2-10 所示。

$$X^*_{adv} = \arg\min_{X_{adv}} \mathcal{L}_{adv}(X_{adv}, Y_{target}, Y_{true}; \theta^*) + ||X_{adv} - X||_\infty \tag{2-10}$$

2.2.2 对抗样本与生成对抗网络的区别

生成对抗网络（Generative Adversarial Networks, GAN）[44] 是一类生成模型，其主要结构包括一个生成器 (Generator, G）和一个鉴别器（Discriminator, D），如图 2-2 所示。其中生成器接受随机噪声 $z \sim p_z(z)$ 作为输入，生成样本 $X_g = G(z)$；同时从真实数据集中采样得到真实样本 $X_r \sim p_{data}X$。鉴别器的作用就是区分生成样本 X_g 和真实数据 X_r 的真假。在训练生成器的时，鉴别器参数保持不变；而在训练鉴别器的时，生成器的参数保持不变。随着训练的进行，最终鉴别器无法区分真实样本和生成器生成的假样本，就达到了生成器“对抗”鉴别器的目的。

GAN 中鉴别器的优化目标如公式 2-11 所示，可以看做是一个交叉熵损失函数，目的就是最大化区分鉴别器对于真实样本 $D(x)$ 和生成样本 $D(G(z))$ 的类别。

$$\max_{\mathrm{D}} \mathbb{E}_{\mathrm{x}\sim \mathrm{p}_{\mathrm{data}}} [\log \mathrm{D}(\mathrm{x})] + \mathbb{E}_{\mathrm{z}\sim \mathrm{p}_{\mathbf{z}}} [\log(1 - \mathrm{D}(\mathrm{G}(\mathrm{z})))] \tag{2-11}$$

生成器的优化目标公式如 2-12 所示，目的就很简单，就是最小化生成器生成的数据与真实数据之间的差别。

$$\min_{G} \mathbb{E}_{\mathrm{z}\sim \mathrm{p}_{\mathrm{z}}} [\log(1 - \mathrm{D}(\mathrm{G}(\mathrm{z})))] \tag{2-12}$$

将生成器和鉴别器的优化目标统一在一起的话得到公式 2-13。

$$\min_{G} \max_{D} \mathbb{E}_{\mathrm{x}\sim p_{\mathrm{data}}} [\log \mathrm{D}(\mathrm{x})] + \mathbb{E}_{\mathrm{z}\sim \mathrm{p}_{\mathrm{z}}} [\log(1 - \mathrm{D}(\mathrm{G}(\mathrm{z})))] \tag{2-13}$$

如果将恶意流量检测模型作为鉴别器，那么最终训练好的生成器生成的样本在就可以绕过检测模型的检测，实现了对抗攻击。但是基于 GAN 的方式产生的“生成样本”和公式 2-8 所示产生的对抗样本是有区别的。在 GAN 模型架构中，生成样本的所有比特都来源于生成器的输出，而对抗样本本身属于真实样本集中的数据，只是在目标模型梯度的指导下将部分特征进行轻微扰动。虽然生成样本和对抗样本都可以成功的绕过目标模型的检测，但是其生成的方式却有很大区别。

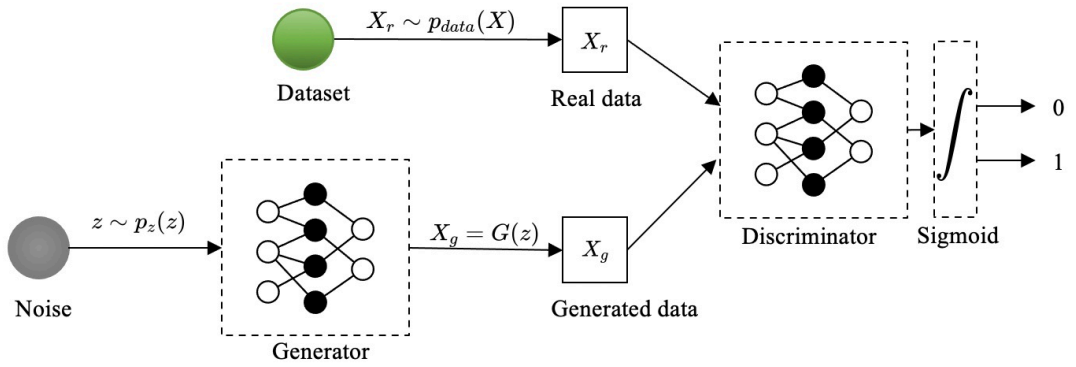


图 2-2 生成对抗网络示意图

Figure 2-2 Generative adversarial network diagram

2.3　机器学习模型的评估指标

由于恶意流量检测本质上是一个二分类问题，因此根据每个样本的真实标签 Y_{true} 和模型预测的标签 $Y_{predict}$ 的不同，每个样本在经过恶意流量检测模型预测后可以划分为如表 2-1 所示的四种类别，同时该表也称作二分类结果的混淆矩阵。

表 2-1 二分类结果混淆矩阵

Table 2-1 Confusion matrix for binary classification

True label (Y_{true})	Predicted label ($Y_{predict}$)	
	$Y^m_{predict}$	$Y^b_{predict}$
Y^m_{true}	True Positive(TP)	False Negative(FN)
Y^b_{true}	False Positive(FP)	True Negative(TN)

对于机器学习模型，本研究使用精确率（Precision, P），召回率（Recall, R）和 F1 值三个指标来评估该模型的性能。这三个指标的计算方法如公式 2-14 所示。

$$\begin{cases} Precision = \dfrac{TP}{TP+FP} \\ Recall = \dfrac{TP}{TP+FN} \\ \dfrac{1}{F1} = \dfrac{1}{2}\left(\dfrac{1}{Precision} + \dfrac{1}{Recall}\right) \end{cases} \tag{2-14}$$

精确率计算的是模型报告为正的样本中实际为正的比例，衡量的是模型对正样本结果中的预测准确程度。召回率计算的是模型将实际为正的样本报告为正的比例，对于恶意流量检测的场景来说比较重要。而 F1 值则是取精确率和召回率的一个平衡点。

在对抗样本攻击场景下，本研究更加关注目标分类器是否能够正确识别恶意样本，因此本文使用逃避检测率（Evasion Detection Rate, EDR）作为指标来评估对抗样本攻击。EDR，又称假阴性率（False Negative Rate, FNR）或者称为漏报率，是指实际为恶意但预测为良性的样本数与实际恶意样本总数的比率。EDR的计算方式如公式2-15 所示。

$$EDR = \frac{FN}{TP + FN} \tag{2-15}$$

另外，本文所使用的所有评估指标均是经过宏平均的。

第 3 章　恶意加密流量检测模型脆弱性分析

3.1　引言

对抗样本攻击是在最近几年被计算机视觉社区提出，大多数基于机器学习或者深度学习的恶意加密流量检测模型在设计之初并没有考虑到要防范对抗样本的攻击，因此现有的使用机器学习算法作为检测引擎的恶意加密流量检测模型在面对对抗样本攻击时的脆弱性分析不够完善。为了解决这个问题，本章通过实验分析了各种类型的恶意加密流量检测模型所使用的的流量特征和检测算法的脆弱性。

评估结果总结出一批在不同数据集上泛化良好、对抗显著性高、计算简单的特征集合，给对抗样本攻击时的特征选择提供一定的指导。实验结果显示在没有经过针对性防御的情况下，大部分基于机器学习的恶意加密流量模型在面对对抗样本攻击时的鲁棒性是不足的。

本章按照如下结构进行组织。3.2 节介绍了本文实验中所使用到的一些设置，包括数据集、特征、检测模型等；3.3 节使用信息增益和基尼指数评估特征的重要性；3.4 节使用对抗性显著图评估了特征的对抗显著性；3.5 节定性的分析了扰动不同特征的难易程度；3.6 节对特征评估的结果进行汇总；3.7 节使用了现有的对抗样本攻击方法评估了检测模型的鲁棒性；3.8 节最后对于本章进行小节。

3.2　实验设置

3.2.1　数据集介绍

为了充分保证实验的有效性，本文使用了 CICIDS2017[45] 和 MTA[46] 这个两个常见的恶意流量数据集进行实验，具体的信息如下。

CICIDS2017 数据集包含良性流量和最新的常见网络攻击流量，类似真实世界的网络流量数据。本文选用了五种最常见的网络攻击流量作为正样本，以及相同数量的良性流量作为负样本。MTA 数据集采集了从沙盒环境捕获的 C&C 通信流量长达 10 年，本文收集了从 2013 年到 2022 年的 1621 个 pcap 文件，并且将每条 TLS 流的 SHA1 指纹与 SSL Blacklist[47] 进行对比，从而对齐进行标定。最后本文也是选择了五种包含足够数量流量的恶意软件家族作为正样本，以及相同数量的良性流量作为负样本。具体信息如表 3-1 所示。

在每个数据集中，本文将数据划分为三个部分，其中训练集占比 70%，验证集占比 20%，测试集占比 10%。训练集主要用于训练恶意加密流量检测模型，验证集主要用于调整模型的超参数以及对模型的性能进行初步评估，测试集主要用于评估模型的泛化能力，并且在对抗有样本攻击实验中，使用 50% 测试集的数据生成对抗样本，用以测试目标模型对于对抗样本的鲁棒性。本文所有实验均使用五折交叉验证以确保实验数据的准确性。

表 3-1 数据集信息总结

Table 3-1 Summary of datasets in evaluation

数据集名称	提取特征类型	恶意流量类型	流数目
CICIDS2017	统计特征	Botnet	1,966
		Fuzzing	231,073
		PortScan	127,537
		BruteForce	13,835
		DDoS	97,718
MTA	统计特征 序列特征	Tofsee	22,947
		Dridex	8,165
		Quakbot	706
		TrickBot	657
		Gozi	585

3.2.2 恶意加密流量检测模型介绍

流量数据经过特征提取，形成特征向量后就可以输入到机器学习算法中。而机器学习算法经过多年的发展，诞生了众多不同架构、不同类型的算法模型，而这些模型也被广泛的应用在恶意加密流量检测中。为了充分评估使用不同类型和不同架构机器学习算法的恶意加密流量检测模型的鲁棒性，本文选取了 7 种不同类型的算法模型作为目标模型。

这些模型和的具体信息如下所示。

- 逻辑回归（Logistic Regression, LR）[48]：逻辑回归是一种广义的线性回归分析模型，是一个经典的二分类模型。在线性回归模型的基础上使用逻辑函数（$S(x) = \frac{1}{1+e^{-x}}$）将阈值映射到 [0, +1] 形成概率值从而进行二分类。本文使用的是一个正则化系数为 0.3 的逻辑回归模型。
- 决策树（Decision Tree, DT）[49]：决策树模型是一种经典的树模型，通过计算每个特征的信息增益或者基尼指数进行决定如何分裂，最终形成一棵分类树。
- 支持向量机（Support Vector Machine, SVM）[41]：支持向量机模型是通过定义在特征空间上的间隔最大的线性分类器，其学习策略就是使样本间隔最大。本文使用的是一个使用 RBF 核的 SVM 模型。
- 孤立森林（Isolation Forest, IF）[50]：孤立森林模型是一个经典的非监督学习分类模型，常应用在异常检测领域，算法直接刻画样本之间疏离程度。
- 深度神经网络（Deep Neural Network, DNN）[42]：深度神经网络模型是由基础的神经元模型组成的，一般包含输入层、多个隐藏层和输出层，每个层之间使用激活函数进行非线性转化。本文中使用的深度神经网络模型包含一个输入层，输入特征数根据不同数据集和不同的特征集不同；三个隐藏层，神经元数量分别为 2048,1024,512；最后是一个包含了两个神经元的输出层。
- 长短期记忆网络（Long Short-Term Memory, LSTM）[43]：长短期记忆网络模型是一种非常擅于挖掘序列数据的模型，在循环神经网络的基础上解决了梯度消失和梯度爆炸的问题。本文使用的 LSTM 模型的结构如下，包含一个 embedding

层，一个双向 LSTM 层和一个线性层。

- FS-Net[28]: FS-Net 模型是一个典型的端到端模型，拥有强大的数据表征能力，报告了优秀的流量分类性能。本文使用的 FS-Net 模型与原本报告的结构一致。

在传统机器学习算法中，LR、DT、SVM 是监督学习的代表，IF 是非监督学习的代表；在神经网络模型中，DNN 是前馈神经网络的代表，而 LSTM 和 FS-Net 是序列模型的代表，并且 FS-Net 代表着端到端流量分类模型的最好水平。

3.2.3　对抗样本攻击方法介绍

为了充分评估对抗样样本攻击对于恶意加密流量检测模型的影响，本文使用了四种经典在计算机视觉领域应用非常成功的白盒特征空间对抗样本算法，它们的信息如下所示。

- FGSM[14]: FGSM 是一种快速的对抗样本生成算法，通过计算样本对损失函数的梯度，再经过符号函数转为为扰动，对抗样本生成公式如 3-1 所示，其中 ϵ 为扰动幅度。

$$\rho = \epsilon \operatorname{sign}\left(\nabla \mathcal{L}\left(\boldsymbol{\theta}, \mathbf{X}_c, L\right)\right) \tag{3-1}$$

- BIM[31]: BIM 在 FGSM 的基础上增加了迭代的过程，所以生成对抗样本的速度会降低，但是对抗样本的精度会提高。迭代公式如 3-2 所示

$$\mathbf{X}_{adv}^{i+1} = \operatorname{Clip}_{\epsilon}\left\{\mathbf{X}^{i} + \alpha \operatorname{sign}\left(\nabla \mathcal{L}\left(\boldsymbol{\theta}, \mathbf{X}_{adv}^{i}, L\right)\right)\right\} \tag{3-2}$$

- JSMA[32]: JSMA 算法区别于基于梯度的对抗样本生成算法，通过每次修改特征向量中的某几个特征，最终得到特征对于分类结果变化的显著图，然后选择显著图中值最高的特征进行扰动，显著图的生成方式请见 3.4.1 小节。
- C&W[16]: C&W 方法在 L-BFGS 的基础上进行改进，首先在距离度量上采用了三种距离度量方式，另外使用特殊的损失函数 f 代替分类器的原本的损失函数 $\mathcal{L}$(原文提出了 9 种损失函数，例如 $f_1\left(x'\right) = -\operatorname{loss}_{F,t}\left(x'\right) + 1$)，C&W 方法如公式 3-3 所示。

$$\begin{aligned} &\min \|\rho\|_p + c \cdot f\left(X_c + \rho\right) \\ &\text{s.t. } X + \rho \in [0,1]^n \end{aligned} \tag{3-3}$$

3.2.4　特征提取

不论检测引擎是传统的机器学习算法还是深度学习算法，现有基于机器学习算法的加密恶意加密流量检测模型的检测流程大致分为两个步骤。第一步也是最为关键的一步就是从原始的计算机网络流量中提取有效可靠特征，并且大多数时候需要提取一组特征集合形成特征向量。之后将这个特征向量输入给机器学习算法，用于机器学习模型的训练。特征向量质量的高低在很多时候将会直接影响检测算法的性能，甚至很多工作都将工作重心放在特征提取上，而后面的检测算法却使用较为简单的算法。

本文使用的流量特征如表 3-2 所示。其中统计特征来自于 CICFlowMeter[51] 这款流量提取工具，CICFlowMeter 提供 77 种不同的流量特征，按照其提取的位置不同，又划分为基于时间的特征、基于包长的特征和其他特征三个部分。而序列特征部分则使用了两种常见序列特征，包长序列和时间间隔序列。

表 3-2 流量特征表

Table 3-2 Traffic Features

No.	特征名称	No.	特征名称	No.	特征名称
1	Flow Duration	27	Bwd IAT Std	53	Avg Fwd Segment Size
2	Total Fwd Packets	28	Bwd IAT Max	54	Avg Bwd Segment Size
3	Total Backward Packets	29	Bwd IAT Min	55	Fwd Header Length.1
4	Total Length of Fwd Packets	30	Fwd PSH Flags	56	Fwd Avg Bytes/Bulk
5	Total Length of Bwd Packets	31	Bwd PSH Flags	57	Fwd Avg Packets/Bulk
6	Fwd Packet Length Max	32	Fwd URG Flags	58	Fwd Avg Bulk Rate
7	Fwd Packet Length Min	33	Bwd URG Flags	59	Bwd Avg Bytes/Bulk
8	Fwd Packet Length Mean	34	Fwd Header Length	60	Bwd Avg Packets/Bulk
9	Fwd Packet Length Std	35	Bwd Header Length	61	Bwd Avg Bulk Rate
10	Bwd Packet Length Max	36	Fwd Packets/s	62	Subflow Fwd Packets
11	Bwd Packet Length Min	37	Bwd Packets/s	63	Subflow Fwd Bytes
12	Bwd Packet Length Mean	38	Min Packet Length	64	Subflow Bwd Packets
13	Bwd Packet Length Std	39	Max Packet Length	65	Subflow Bwd Bytes
14	Flow Bytes/s	40	Packet Length Mean	66	Init_Win_bytes_forward
15	Flow Packets/s	41	Packet Length Std	67	Init_Win_bytes_backward
16	Flow IAT Mean	42	Packet Length Variance	68	act_data_pkt_fwd
17	Flow IAT Std	43	FIN Flag Count	69	min_seg_size_forward
18	Flow IAT Max	44	SYN Flag Count	70	Active Mean
19	Flow IAT Min	45	RST Flag Count	71	Active Std
20	Fwd IAT Total	46	PSH Flag Count	72	Active Max
21	Fwd IAT Mean	47	ACK Flag Count	73	Active Min
22	Fwd IAT Std	48	URG Flag Count	74	Idle Mean
23	Fwd IAT Max	49	CWE Flag Count	75	Idle Std
24	Fwd IAT Min	50	ECE Flag Count	76	Idle Max
25	Bwd IAT Total	51	Down/Up Ratio	77	Idle Min
26	Bwd IAT Mean	52	Average Packet Size		
78	Packet Length Sequence	79	time interval sequence		

根据特征提取的层级不同，可以将特征分为包级别的特征和流级别的特征。包级别的特征以数据包为单位提取，例如提取 TCP Flag、包大小等；流级别的特征以流为单位提取统计特征，例如流速、平均包长。根据特征提取方式的不同，可以将特征分为统计特征和序列特征。统计特征是计算流量的各种统计数据，例如最大最小值、平均值、方差等；序列特征则是一种新兴的特征，例如包长序列就是将一条流的每个数据包的包长组成一个序列，其中包含的时间信息，在很大程度上能够反映流量的行为。根据提取特征的位置不同，可以将会特征分为基于时间的特征和基于空间的特征，基于时间的基本上都是从时间间隔导出的各种

统计值，而基于空间的特征值则都是从包长导出各种统计值。

3.3　特征重要性评估

对于基于机器学习的恶意加密流量检测模型来说，特征的质量严重影响检测算法的准确率。因此本节本文将会对常见的统计特征和序列特征进行评估，给出各个特征对于不同检测算法分类的贡献度。

本文使用信息增益（Information Gain, IG）和基尼指数（Gini Index, GI）来评估特征对于分类的贡献度。

3.3.1　信息增益

信息增益的概念来源于信息论，本文知道任何一件事 x 的信息量为 $h(X) = -logp(x)$，而随机变量 X 的信息熵就是所有可能发生的事件带来的信息量的期望 $H(X) = -\sum_{i=1}^{n} p\left(x_i\right) \log p\left(x_i\right)$。信息增益则是用来衡量一个样本集合 D 在经过某个特征 a 划分为若干个集合 D_i 之后纯度的提升程度，计算方法如公式 3-4 所示。

$$IG(D, a) = H(D) - \sum_{i}^{n} \frac{|D_i|}{|D|} H(D_i) \tag{3-4}$$

本文在 CICIDS2017 和 MTA 两个数据集上评估了 CICFlowMeter 中 77 个统计特征的信息增益，实验结果如图 3-1 所示。横轴表示特征的序号，纵轴表示信息增益。图中明显出现一些区域的信息增益高于周围的地方，说明这部分特征对于分类的贡献度更大，本文高亮了这些区域。77 个统计特征虽然对两个数据集的分类结果贡献度不完全一致，但是仔细对比两张图的高亮区域会发现其中存在重合部分，说明有一部分特征对于多个数据集的效果较好。

3.3.2　基尼指数

数据集 D 的纯度除了可以使用信息熵来表示之外，还可以使用基尼值（如公式 3-5 所示）来表示。经过属性 a 的划分之后，表示纯度提升的基尼指数定义如公式 3-6 所示。

$$Gini(D) = \sum_{i=1}^{|y|} p(x_i) * (1 - p(x_i)) = 1 - \sum_{i=1}^{|y|} p(x_i)^2 \tag{3-5}$$

$$Gini_index(D, a) = \sum_{i=1}^{n} \frac{|D^i|}{|D|} Gini(D^i) \tag{3-6}$$

为了计算每个特征的基尼指数，本文使用到随机森林算法，算法就是计算每个特征在随机森林里面的每棵树上的基尼指数，然后取平均值作为这个特征整

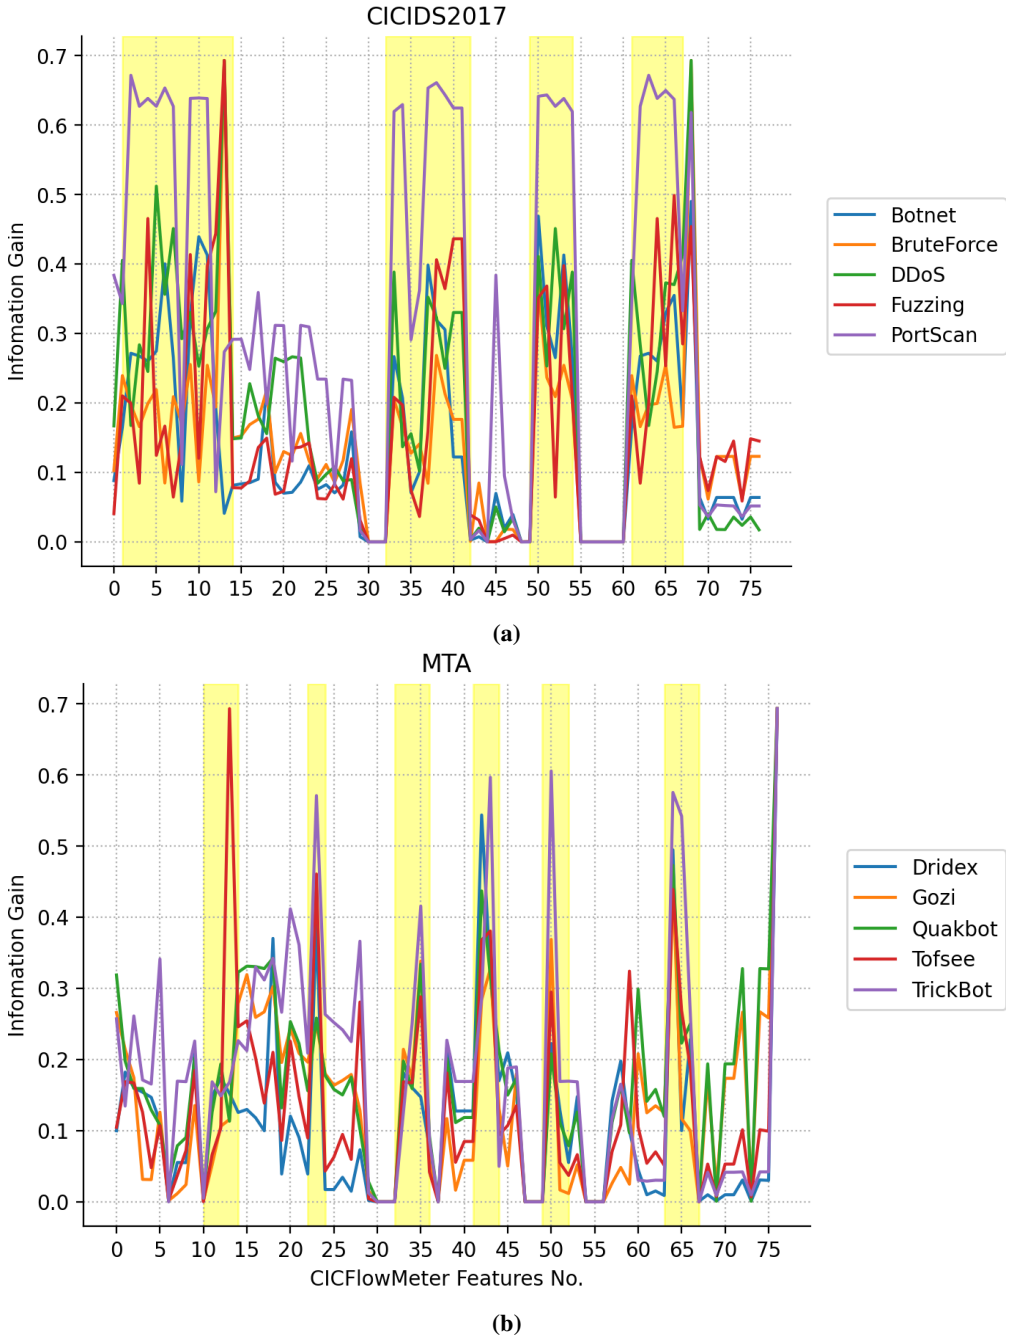


图 3-1 信息增益 (a) CICIDS2017 数据集 (b) MTA 数据集

Figure 3-1 Infomation gain.(a) CICIDS2017 dataset, (b) MTA dataset

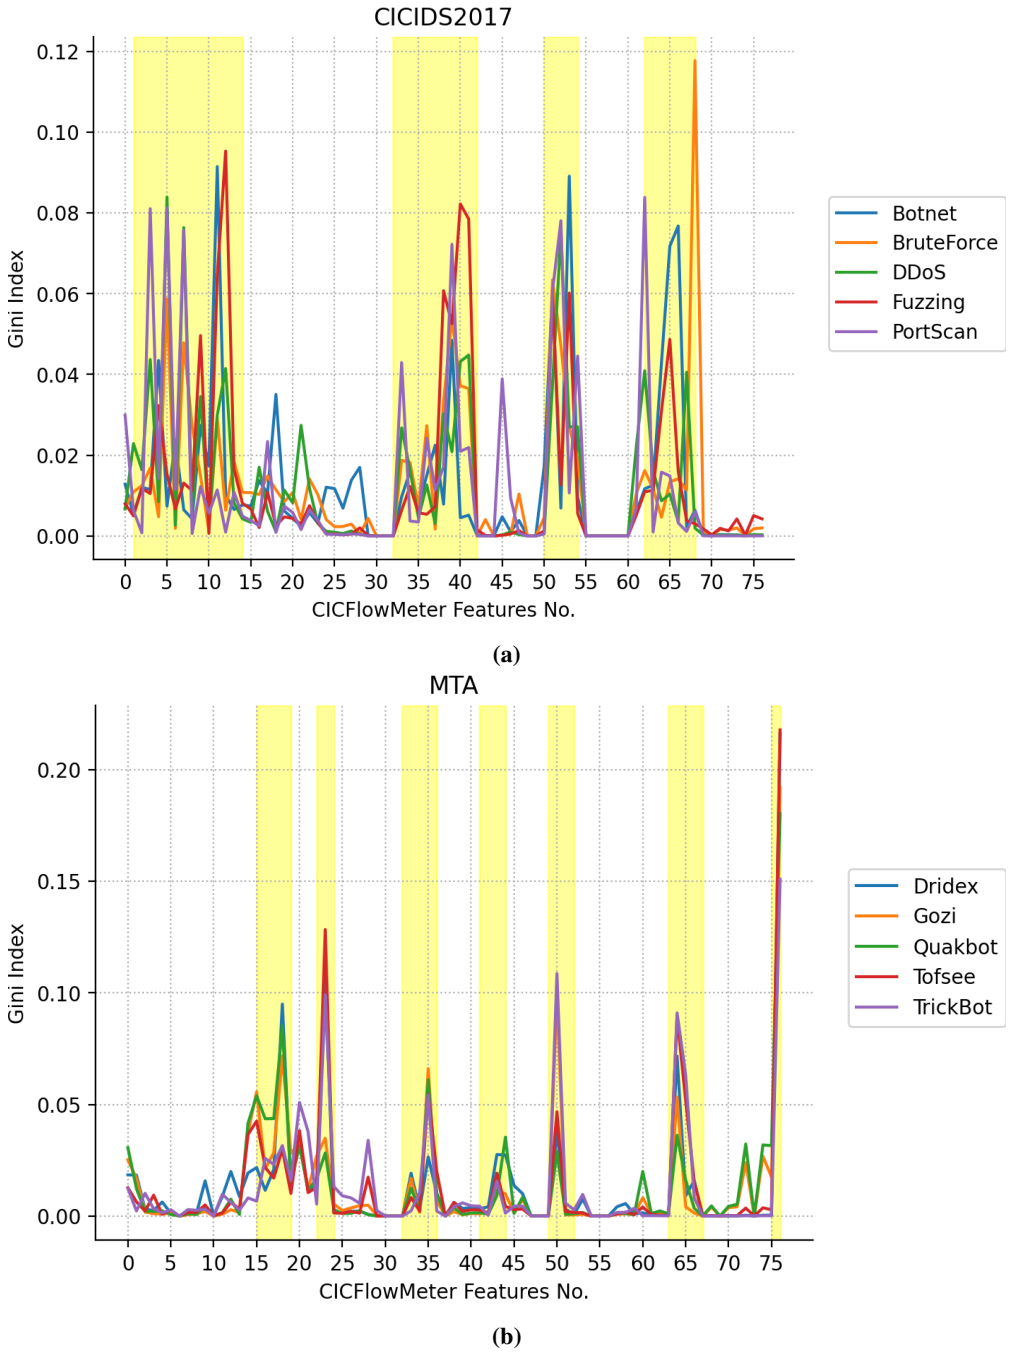


图 3-2 基尼指数 (a) CICIDS2017 数据集 (b) MTA 数据集

Figure 3-2 Gini index.(a) CICIDS2017 dataset, (b) MTA dataset

体的基尼指数，结果如图 3-2 所示，可以看出基尼指数来评估特征的重要程度，得到的结果与信息增益评估的大致相同。

CICFlowMeter 特征集合包含的 77 维特征在使用信息增益和基尼指数进行重要性评估之后，得到了类似的结果。本文将重要程度较高的特征序号列出如表 3-3 所示（序号对应的特征可以在表 3-2 中查询）。

表 3-3 特征分类贡献度评估

Table 3-3 Feature classification contribution evaluation

数据名称	重要特征（信息增益）	重要特征（基尼指数）
CICIDS2018	1-14, 32-42, 49-54, 61-67	1-14, 32-42, 50-54, 62-68
MTA	10-14, 22-24, 32-36, 41-44, 49-52, 63-67	15-19, 22-24, 32-36, 41-44, 49-52, 63-67, 75-76
Both	10-14, 32-36,49-52, 63-67	32-36, 50-52, 63-67

3.4 特征对抗显著性评估

3.4.1 对抗性显著图的概念

Papernot 等[32] 提出对抗性显著图的概念，类似于计算机视觉社区中的热力图。算法利用雅克比矩阵，计算从输入特征到输出特征值之间的对抗显著性。计算对抗性显著图分为两个大的步骤，下面将详细阐述算法步骤。

- 计算前向导数: 计算模型输出的每个类别的概率对于输入特征向量的偏导数，该偏导数表示的是特征向量中每个特征对于分类结果的影响程度，计算公式如 3-7 所示。

$$J_F(\mathbf{X}) = \frac{\partial \mathbf{F}(\mathbf{X})}{\partial \mathbf{X}} = \left[\frac{\partial \mathbf{F}_j(\mathbf{X})}{\partial x_i}\right] \tag{3-7}$$

- 计算显著图：假设需要将样本误分类为 t，为了达到这个目的，需要不断增大 $F_t(X)$ 的概率，当 $j \neq t$ 时，$F_j(X)$ 需要不断减小，一直减小到 $t = \arg\max x_j F_j(X)$。具体的计算公式如 3-8 所示，其中第一行表示拒绝到目标类的前向导数为负值，或者除了目标类之外类别的前向导数之和为正数的所有特征；第二行则定义了其他特征的对抗显著性。

$$S(\mathbf{X}, t)[i] = \begin{cases} 0 \text{ if } J_{it}(\mathbf{X}) < 0 \text{ or } \sum_{j \neq t} J_{ij}(\mathbf{X}) > 0 \\ J_{it}(\mathbf{X}) \left| \sum_{j \neq t} J_{ij}(\mathbf{X}) \right| \text{ otherwise} \end{cases} \tag{3-8}$$

3.4.2 计算对抗性显著图

为了评估不同特征的对抗显著性，本文选择的特征包含统计特征和序列特征，同时目标模型为深度神经网络，通过分别计算两种不同类型的特征在两个数据集上的对抗显著性，来评估特征的对抗显著性。

本文使用深度神经网络作为目标模型，首先在 CICIDS2017 数据集上计算了 77 维统计特征的对抗显著性。对抗攻击的目标类别是良性，即对抗攻击的目的

是让目标模型将恶意流量误分类为良性，对于每个恶意流量类型，本文随机选择 10 个对抗样本，计算其对抗性显著性，实验结果如图 3-3 所示。

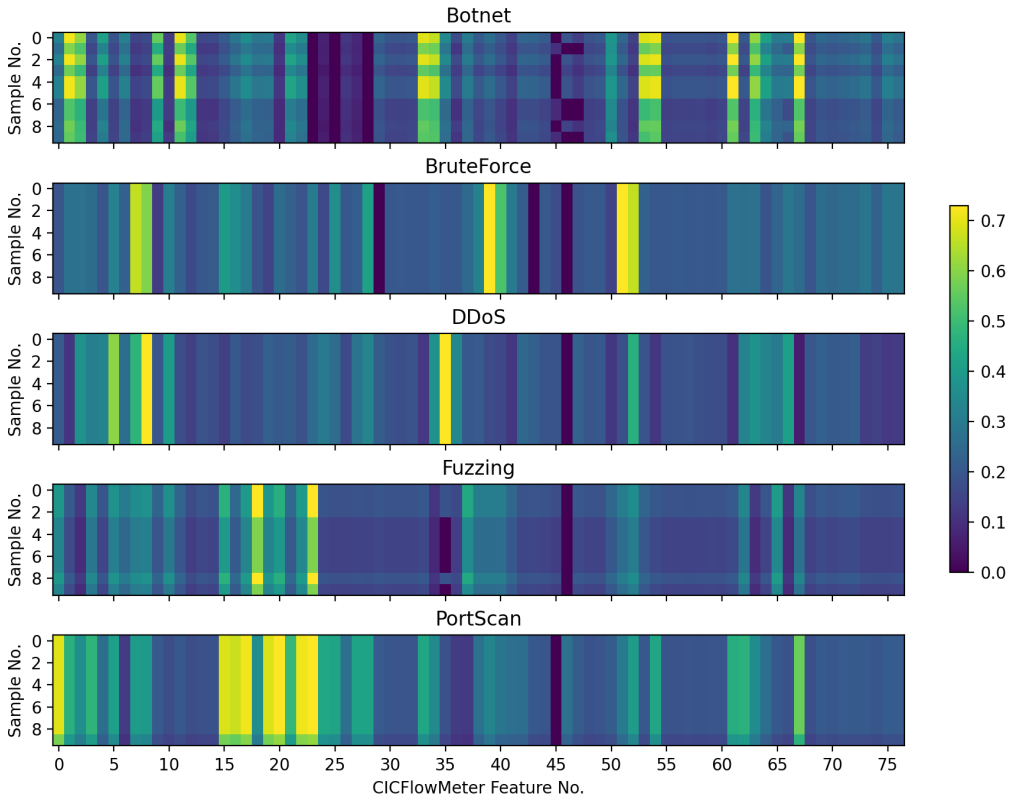


图 3-3 统计特征对抗性显著图（在 CICIDS2017 数据集上实验）

Figure 3-3 Statistical feature adversarial saliency map (experimented on CICIDS2017 dataset)

通过对抗性显著图可以非常明显的观察到如下两个规律。第一，对于每种恶意流量样本来说，对抗最显著的特征基本上都是固定的，例如对于 PortScan 类型的恶意流量来说，CICFlowMeter 特征集的第 14 到第 23 个特征的对抗效果最为显著，并且大部分样本的对抗性最显著的特征都是一致的。第二，通过对比对抗性显著图与上一小节的特征有效性的实验结果，可以发现对抗性比较显著的特征范围和分类有效性比较显著的特征范围有一定程度上的重合，即有一部分特征对于分类的贡献度比较大，同时对抗扰动时也是最容易使目标模型的分类结果发生改变的，这样的特征就可以被确定为关键特征。

第二个特征对抗显著性实验是在 MTA 数据集上做的，使用的特征是长度为 80 的包长序列，目标模型依然是 DNN，对于每一种恶意流量类型，随机选择 10 个样本，计算其对抗性显著图，实验结果如图 3-4 所示。

通过序列特征的对抗性显著图本文可以看到，对于序列特征而言，对抗效果比较显著的特征都集中在序列的后半部分，这意味着如果本文对序列特征进行对抗的话，使用 padding 的方式在序列后面填充数据包的效果比修改已有数据包的效果好。

对抗性显著图是一个非常重要的工具，对于白盒攻击而言，本文通过对抗性

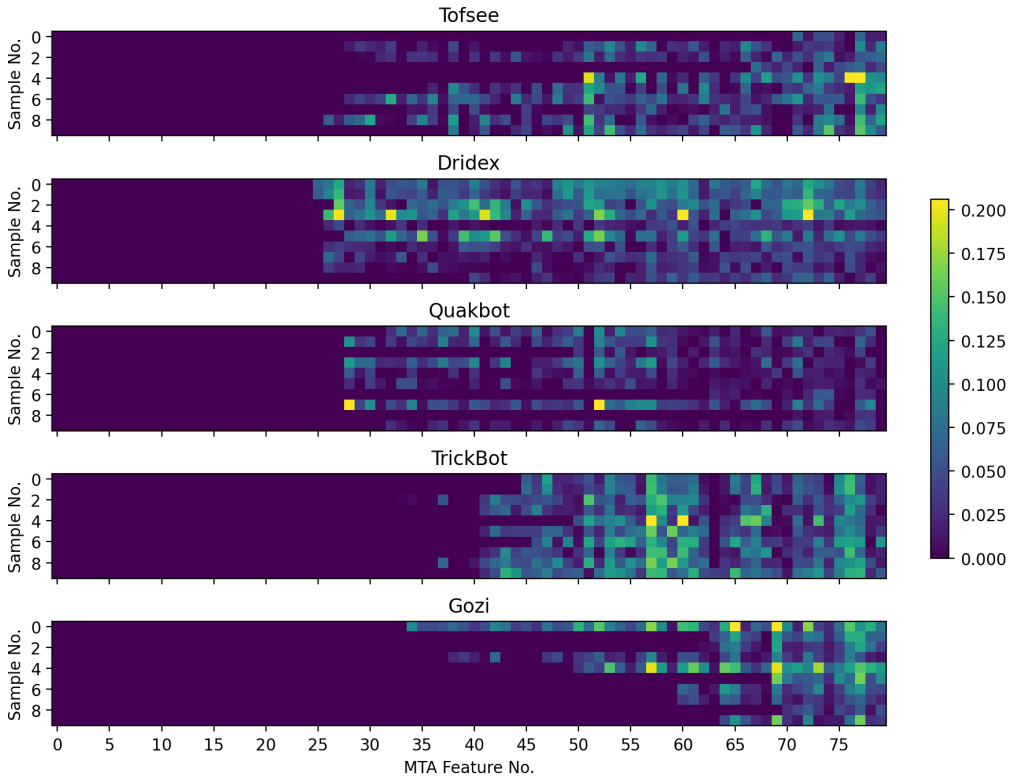


图 3-4 序列特征对抗性显著图 (在 MTA 数据集上实验)

Figure 3-4 Sequence feature adversarial saliency map （experimented on MTA dataset)

显著图，可以清楚的观察到扰动哪些特征的作用最显著，因此就可以在付出最小成本的情况下实现最有效的对抗攻击。而对于黑盒攻击而言，即便攻击者不知道目标模型会选用哪些特征，但是也可以对比特征有效性以及特征的对抗性显著图进行筛选，选择关键的特征进行对抗性扰动。

3.5 特征扰动难易度评估

在实际进行对抗性扰动时，还需要考虑特征对抗的难易程度或对抗的成本。由于之前所做的实验都是直接在特征向量上进行扰动，可以不用考虑流量数据的复杂性，但是实际攻击场景下攻击者很难直接操作目标模型中的特征向量，具有实际意义的对抗攻击应该是扰动原始计算机流量。为了方便后续研究的展开，本节定性分析了各个类型特征的扰动的难易程度。

从原始计算机流量到特征是一个单向不可逆的过程，因此在这个单向过程中进行的计算过程越复杂，从特征换源到原始流量也就越困难。为了衡量特征提取过程的复杂程度，本文定义了特征的计算次数的概念。

定义 3.1. 特征的计算次数: 表示从原始的流量数据到特征需要进行的计算次数。

最简单的特征只需要经过一次计算，例如某个数据包的包长，某两个数据包之间的时间间隔；而中等复杂的特征则需要在简单特征的基础上计算统计值，属于二次计算的特征，最大值，最小值和平均值；而复杂特征的量比较大，例如

熵值，或者是在简单特征上计算的复杂统计值，例如方差、标准差等。表 3-4 对特征提取需要的计算次数进行了整理。

表 3-4 特征提取复杂度

Table 3-4 Feature extraction complexity

特征类型	复杂程度	计算次数	特征序号
统计特征	简单	1	29-32, 42-49
	中等	2	0-7, 9-11, 15, 17-20, 22-25,27-28,33-34, 37-39,50-69, 71-73,75-76
	复杂	3	8,12-14,16, 21,26,35-36,40-41,70,74
序列特征	简单	1	包长序列、时间间隔序列

3.6　特征评估结果汇总

为了直观的体现各个评估实验之间的关联，在 CICIDS2017 数据集上，本文对统计特征进行的所有评估工作进行汇总。对于特征重要性而言，本文将图 5-3a 所示五种不同类型流量所提特征的信息增益和基尼指数计算平均值；对于特征对抗显著性而言，本文将图 3-3 所示的所有样本特征对抗显著性进行平均；对于特征对抗难易度而言，本文直接使用表 3-4 所示的各个特征计算次数。最终汇总成图 3-5 所示的结果。

从汇总结果可以看到，信息增益和基尼指数所反映出的特征重要性的变化趋势基本一致，即这两个指标评估出的重要特征基本一致。再结合特征对抗显著性的话，大部分对抗性显著图报告的对抗显著性高的特征同时也是重要程度较高的特征。例如特征 No.1-14, No.34-42, No.51-55, No.62-69 这几组特征的信息增益、基尼指数和对抗性显著性都较高，同时这批特征的计算次数大部分都是两次左右，即大部分特征的计算过程并不复杂，对抗起来较为简单。

特征的重要性决定着目标模型是否决定使用该特征，这对于黑盒场景下的对抗样本攻击来说较为重要，因为只有目标模型选用了该特征才有对抗的意义，否则对抗攻击就会失去原本的效果。特征对抗显著性高的意义在于能够以更加微弱的扰动，更大概率造成目标模型发生分类失误。对特征的扰动越微弱，在实际场景中攻击的成本就越低，因此选用特征对抗显著性高的特征能够大幅降低实际场景中对抗样本攻击的难度。在一定程度上，对抗样本越接近原始样本，对抗样本攻击就越难防御。特征扰动的难易程度意味着从对抗性特征向量转化为对抗性流量的难易程度。越复杂的特征，在转化的过程中对流量的修改程度就越大。因此选用复杂特征进行对抗会大幅提高对抗性流量生成的工程难度。综上所述，选用重要性高、对抗显著性高和计算次数低的特征能够有效降低对抗攻击的难度并且增大攻击成功率。

No.	信息增益	基尼指数	对抗有效性	计算次数	No.	信息增益	基尼指数	对抗有效性	计算次数
1	15.64%	1.29%	49.72%	2	40	35.54%	4.96%	49.24%	3
2	27.25%	1.01%	48.69%	2	41	33.80%	3.76%	40.56%	3
3	30.16%	1.07%	48.19%	2	42	33.80%	3.74%	29.46%	1
4	28.58%	3.27%	43.51%	2	43	0.98%	0.04%	31.36%	1
5	36.18%	2.06%	37.86%	2	44	3.20%	0.09%	23.29%	1
6	35.16%	4.93%	52.31%	2	45	0.01%	0.00%	26.86%	1
7	33.24%	0.93%	33.99%	2	46	10.10%	0.89%	15.81%	1
8	32.34%	4.39%	56.41%	3	47	3.06%	0.25%	10.78%	1
9	15.57%	0.99%	61.99%	2	48	2.66%	0.33%	25.08%	1
10	39.33%	2.77%	36.36%	2	49	0.00%	0.00%	26.21%	1
11	30.77%	0.56%	38.15%	2	50	0.01%	0.00%	27.06%	2
12	40.21%	4.52%	42.17%	3	51	44.84%	0.48%	31.58%	2
13	24.70%	3.08%	32.26%	3	52	36.25%	5.64%	48.68%	2
14	47.89%	1.21%	25.15%	3	53	32.34%	4.39%	56.02%	2
15	14.99%	0.72%	25.02%	2	54	40.21%	4.28%	42.35%	2
16	15.11%	0.64%	52.54%	3	55	33.76%	2.12%	45.35%	2
17	16.36%	0.91%	48.43%	2	56	0.00%	0.00%	25.96%	2
18	18.87%	1.31%	53.16%	2	57	0.00%	0.00%	26.37%	2
19	18.85%	1.02%	47.96%	2	58	0.00%	0.00%	26.39%	2
20	16.61%	0.76%	48.04%	2	59	0.00%	0.00%	26.16%	2
21	16.88%	0.67%	48.92%	3	60	0.00%	0.00%	25.82%	2
22	14.27%	0.77%	43.96%	2	61	0.00%	0.00%	26.12%	2
23	19.11%	0.92%	50.82%	2	62	27.25%	1.01%	48.47%	2
24	16.39%	0.48%	55.12%	2	63	28.58%	3.27%	43.96%	2
25	10.97%	0.37%	31.82%	2	64	30.16%	1.05%	47.79%	2
26	11.75%	0.32%	33.61%	3	65	36.18%	2.06%	37.74%	2
27	8.58%	0.21%	25.64%	2	66	37.22%	3.18%	39.82%	2
28	11.67%	0.38%	32.64%	2	67	40.52%	2.28%	34.92%	2
29	15.83%	0.41%	37.17%	1	68	27.46%	1.18%	53.31%	2
30	3.20%	0.09%	23.56%	1	69	58.98%	2.70%	25.74%	2
31	0.00%	0.00%	26.14%	1	70	7.62%	0.07%	31.20%	3
32	0.00%	0.00%	26.04%	1	71	4.91%	0.01%	29.28%	2
33	0.00%	0.00%	26.53%	2	72	7.62%	0.08%	30.89%	2
34	33.76%	2.09%	45.19%	2	73	7.46%	0.07%	31.52%	2
35	26.73%	1.33%	46.99%	3	74	8.40%	0.14%	29.71%	3
36	14.40%	0.57%	42.18%	3	75	4.27%	0.01%	25.99%	2
37	14.86%	1.69%	27.27%	2	76	8.47%	0.15%	30.51%	2
38	32.97%	0.92%	36.19%	2	77	8.03%	0.14%	29.59%	2
39	39.56%	2.99%	36.27%	2					

图 3-5 特征评估结果汇总

Figure 3-5 Summary of feature evaluation results

3.7　目标算法鲁棒性评估

本文对现有基于机器学习的恶意加密流量检测模型的鲁棒性进行评估。实验设置如下：本文使用了 3 种神经网络模型和 5 中机器学习模型作为对抗样本攻击的目标模型，在 MTA 数据集上使用包长序列特征，训练了这些目标模型；同时，为了使评估的数据更加真实，这里使用黑盒攻击（具体方法见第 4 章），并且使用了三种神经网络模型作为代理模型；实验采用检测逃逸率（EDR）作为指标。实验结果如表 3-5 所示。

表 3-5 鲁棒性评估实验结果

Table 3-5 Robustness evaluation experimental results

	FGSM							
Malware	Target(ψ_t)							
	FS-Net	DNN	LSTM	SVM	LR	DT	RF	KNN
Tofsee	99.76	2.42	82.72	0.08	3.31	100	10.00	0
Dridex	99.96	2.29	99.75	0.06	95.2	100	50.48	0.33
Quakbot	100	32.01	100	1.30	16.86	100	53.00	1.71
TrickBot	100	1.08	98.46	0	0.31	100	98.31	0
Gozi	100	6.72	100	0.86	34.48	100	99.48	5.00
AVE	**99.94**	8.90	96.19	0.46	30.03	100	62.25	1.40
	BIM							
Malware	Target(ψ_t)							
	FS-Net	DNN	LSTM	SVM	LR	DT	RF	KNN
Tofsee	28.20	79.01	0.15	0.10	20.63	15.1	13.82	1.35
Dridex	41.90	86.80	75.45	0.14	55.74	83.7	82.81	1.33
Quakbot	22.43	65.41	48.57	1.00	3.42	20.51	3.71	1.57
TrickBot	40.46	67.38	11.08	0	0.31	90.46	92.92	1.08
Gozi	31.31	29.48	1.90	0.70	4.31	27.59	28.61	3.97
AVE	32.84	**65.62**	27.43	0.46	16.88	47.47	44.38	1.86
	JSMA							
Malware	Target(ψ_t)							
	FS-Net	DNN	LSTM	SVM	LR	DT	RF	KNN
Tofsee	99.75	2.92	60.30	0.41	37.36	0.02	64.85	1.02
Dridex	100	11.23	99.46	0.34	95.21	85.39	78.10	1.23
Quakbot	95.28	16.86	79.86	1.14	23.43	98.15	73.86	1.57
TrickBot	90.46	0.15	75.54	0	0.15	76.31	99.23	0
Gozi	97.93	4.14	97.76	0.86	55.17	97.76	88.10	5.00
AVE	**96.68**	7.06	82.58	0.55	42.26	71.63	80.79	1.76

通过实验结果可以看出，实验所选的目标算法模型在没有经过特殊设计或者采取对抗性训练等防御性手段的情况下，在面对对抗样本攻击时的鲁棒性是较差。如果攻击者是白盒攻击，即代理模型和目标模型一致的话，目标模型基本对对抗样本攻击没有任何防御力；即使是黑盒攻击，在攻击者不知道目标模型细节的情况下，部分模型依然无法应对对抗样本的攻击。

3.8 本章小结

本章主要对基于机器学习的恶意加密流量检测模型所使用的流量特征和检测算法的脆弱性进行了分析。其中针对流量特征，本文使用了包括信息增益和基尼指数在内的方法评估了不同特征对于分类结果的贡献度，即特征的重要性，选择出了一批重要程度比较高的特征。此外还使用对抗性显著图来对每个特征的对抗显著性进行了评估，评估结果显示：对于统计特征而言，对抗显著性较高的特征不会随着样本发生变化，而是固定在一组特征上，并且这组对抗显著性较高的特征很大程度上也是对于分类比较重要的那批特征；而对于序列特征，对抗显著性较高的特征都分布在序列特征的末尾。本章定性地分析了每个特征进行对抗的难易程度。最后，本文使用黑盒对抗样本攻击评估了 8 种恶意加密流量算法的鲁棒性，结果显示大部分机器学习检测算法在白盒攻击的假设下对于对抗样本攻击的鲁棒性较差。

本章的评估结果一方面证明了现有恶意加密流量检测模型在不采取任何防御措施的情况下，面对对抗样本攻击时的鲁棒性将会较差，会严重影响使用了这些检测模型的应用的安全。另一方面，通过对流量特征的评估，对后续进行黑盒对抗样本攻击的工作提供指导，即尽量选择重要程度较高并且对抗显著性较高的特征进行对抗。

第 4 章　基于对抗样本可转移性的黑盒对抗攻击方法

4.1　引言

在第 3 章中已经分析了基于机器学习的恶意加密流量检测模型在面对对抗样本攻击时的脆弱性，然而现有的对抗样本攻击方法大多是都是采用白盒攻击的假设，这种假设在实际的攻击场景中是不普适的。本章针对现有对抗样本攻击白盒假设不普适的问题，提出适用于恶意加密流量检测模型的黑盒对抗样本攻击方法。

本章提出了能够解释对抗样本可转移性的决策边界理论。基于决策边界理论，使用代理模型生成对抗样本。通过实验探究了代理模型架构、代理模型训练数据、目标模型使用特征和对抗样本扰动幅度是四个决策本方法成功率的关键因素。最终的对抗样本攻击有效性实验证明了本方法攻击未知目标模型的有效性，在代理模型与目标模型架构相似的情况下能够实现 90% 以上的检测逃逸率，即使代理模型架构未知，通过提高代理模型的复杂度，也能对低复杂度的目标模型有一定的攻击效果。

本章按照如下结构进行组织。4.2 节详细介绍了抗样本攻击可转移性的相关知识，并提出对抗样本攻击的决策边界模型；4.3 节提出了对抗样本攻击的威胁模型、待解决的问题以及所遇到的挑战；4.4 节详细的阐述了本章所提出的方法；4.5 节通过丰富的实验研究了影响对抗样本可转移性的四个关键因素，并证明了所提出方法的有效性；最后4.6 节进行对本章进行小结。

4.2　问题背景

4.2.1　白盒假设与黑盒假设

本文在2.2 节中简单的介绍了对抗样本攻击是如何运作的，以 FGSM[14] 方法为例，对抗性扰动 ρ 是普通样本 X_c 在经过目标模型正向传播后，再计算样本对损失函数的梯度得到的 $\rho = \epsilon \operatorname{sign}\left(\nabla \mathcal{L}\left(\theta, \mathbf{X}_c, L\right)\right)$。从上述的计算过程中可以看到，必须需要知道目标模型的完整参数 θ 才能够计算出对抗性扰动。

因此，可以按照攻击者对于目标模型的了解程度，将对抗样本攻击分为白盒攻击、灰盒攻击和黑盒攻击，他们具体的区别如下。

- 白盒攻击：假设攻击者能够获取目标模型的完整信息，包括目标模型的算法架构、超参数等，甚至攻击者能够直接访问目标模型或者在本地运行目标模型的副本。
- 灰盒攻击：假设攻击者能够获取部分目标模型的信息，例如大致算法类型，但是无法直接访问目标模型，更无法在本地部署目标模型。
- 黑盒攻击：假设攻击者不能获取目标模型的任何信息，目标模型在攻击者的视角下是一个完全的黑盒。

4.2.2 对抗样本攻击的理论解释

在 Szegedy 等[13] 首次提出了对抗样本的概念后，不少研究都尝试去解释对抗样本的行为。本文将尝试利用机器学习的决策边界理论来解释对抗样本。

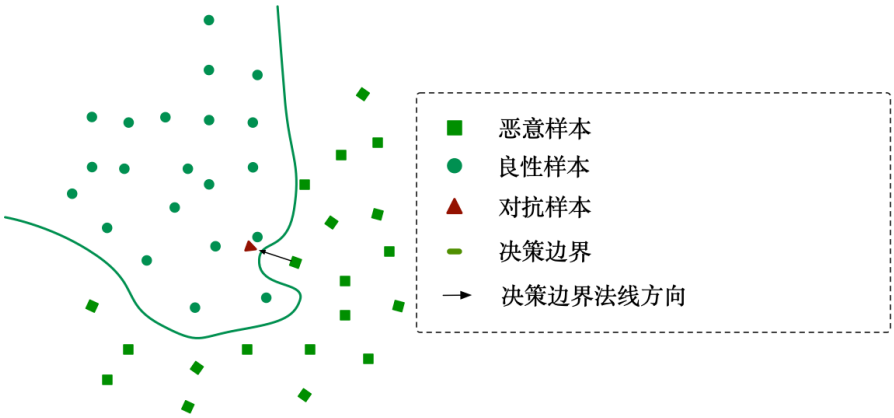


图 4-1 白盒对抗样本攻击决策边界模型

Figure 4-1 Decision boundary model for adversarial example

以二分类为例，机器学习模型本质上就是学习出一个超平面（或者称为决策边界）将训练数据尽可能分开，在遇到新的样本时，利用这个决策边界来判定新样本所属的类别。例如对于逻辑回归分类器来说，其决策边界如公式 4-1 所示。

$$f(x,w)=\frac{1}{1+e^{-\boldsymbol{w}^T\boldsymbol{x}}}=0.5\Rightarrow-\boldsymbol{w}^T\boldsymbol{x}=0 \tag{4-1}$$

机器学习模型的优化目标是尽可能的拟合训练数据，所以其决策边界受训练数据的数据分布影响非常大，或者说对于任何一个数据集来说，都有其隐含的分类超平面，机器学习模型的目的就是努力去寻找这个分类超平面。

如果从决策边界的角度去理解机器学习模型，对抗样本所做的事情就是通过对抗性扰动 ρ，使普通样本 X_c 穿越决策边界从而成为对抗样本 $X_{adv}=X_c+\rho$，而通过控制对抗性扰动的幅度 ϵ，还可以保留原始样本的大部分属性，从而达到欺骗机器学习模型的目的。如图 4-1 所示，对于一个普通样本来说，任何的扰动，即使是随机扰动，都可以是使样本在空间中移动，但是穿越机器学习模型决策边界最快的方向是决策边界的法线方向，在算法中体现的就是计算样本对损失函数的梯度 $\nabla\mathcal{L}\left(\boldsymbol{\theta},\mathbf{X}_c,L\right)$，再通过扰动幅度控制样本沿着决策边界法线方向移动的距离。

通过上面对抗样本的决策边界解释本文可以看出，影响对抗样本攻击成功的关键因素有三个，分别是决策边界、样本移动方向、样本移动距离。这三个因素里面，决策边界由训练数据集的数据分布和目标模型架构决定；而样本移动方向由决策边界和样本位置决定；样本移动距离相当于一个超参数，可以由攻击者通过对抗性扰动幅度进行控制。所以综上所述，决定对抗样本攻击是否成功的三个外界条件是目标模型的训练集的数据分布、目标模型架构和对抗性扰动幅度。具体信息如表所示。

表 4-1 对抗样本决策边界模型总结

Table 4-1 Decision boundary model for adversarial example

关键因素	外界条件	数学表达
决策边界	训练集数据分布、目标模型架构	$\mathbb{X}, \theta$
样本移动方向	样本位置、决策边界	$\nabla \mathcal{L}\left(\boldsymbol{\theta}, \mathbf{X}_c, L\right)$
样本移动距离	扰动幅度（超参数）	ϵ

4.2.3　对抗样本的可转移性

Moosavi-Dezfooli 等[52] 证明了存在一种通用对抗性扰动（Universal Adversarial Perturbations, UAP），任何添加了 UAP 形成的对抗样本都可以对目标拥有一定的对抗攻击能力。该工作证明了对抗样本有一定的可转移性。

定义 4.1. 对抗样本的可转移性：针对模型 A 生成的对抗样本在一定程度上可以用于攻击模型 B，使模型 B 的分类结果发生错误

下面给出对抗样本可转移性的数学定义。给定模型 A($f(\theta_A)$) 和模型 B($f(\theta_B)$)，针对模型 A 生成的对抗样本 X_adv 可以使模型 B 的分类结果错误，如公式 4-2 所示。

$$\begin{cases} X^*_{adv} = \arg\min_X \mathcal{L}_{adv}(X, Y_{target}, Y_{true}; \theta_A) \\ Y_{target} = f(\theta_B; X^*_{adv}) \end{cases} \tag{4-2}$$

4.3　问题提出与方法动机

4.3.1　威胁模型

本文首先定义一下黑盒对抗样本攻击的威胁模型。在一次对抗样本攻击的过程中，一共涉及三个实体，他们分别是：

- 受害者：受害者一般是指感染了恶意软件并被控制的主机（又称僵尸主机），这些主机在恶意软件的控制下通过加密的计算机网络向外界泄露信息或者接受 C&C(Command and Control) 服务器的指令。一般为了受害主机的安全，会在受害主机与外界通信的必经链路节点上部署恶意流量检测系统，用于预防和阻断受害主机与外界的通信。
- 检测者：检测者一般是部署在受害主机与外界通信必经节点上的恶意流量检测系统。检测者一般只会被动的从通信链路中捕获流量数据，而不会对数据进行任何形式的修改。此外检测系统对于攻击者来说都是黑盒的，即攻击者不可能知道检测系统内部的信息，更不可能操作检测系统内部。
- 攻击者：对抗样本攻击场景下的攻击者通常也是使用恶意软件控制受害者主机的人，为了避免受害者主机与自己恶意流量被检测者检测，所以会使用对抗样本攻击来绕过检测系统。对于攻击者，有以下的几点假设，首先攻击者能够控制受害主机和 C&C 服务器，所以能够操作恶意软件上行和下行的流量；此

外，由于检测者使用的检测模型对于攻击者来说是黑盒的，所以攻击者不可能获取检测模型的任何细节；另外，本文假设攻击者是可以访问到检测系统的输出的，即检测系统产生的告警和阻断操作能够被攻击者获取，这个假设是合理的，因为攻击者完全控制了受害主机，所以攻击者完全有可能伪装成受害者去查询这些告警结果。许多商业的恶意流量检测系统，例如 MTD[53] 和 GuardDuty[54]，都提供了查询告警结果的接口。

所以一个典型的黑盒对抗样本攻击场景如图 4-2 所示。攻击者通过一定的手段在本地训练出一个代理模型，用于指导生成对抗性特征，然后将对抗性特征翻译为原始流量，经过伪装的对抗性恶意流量就会绕过检测模型的检测。

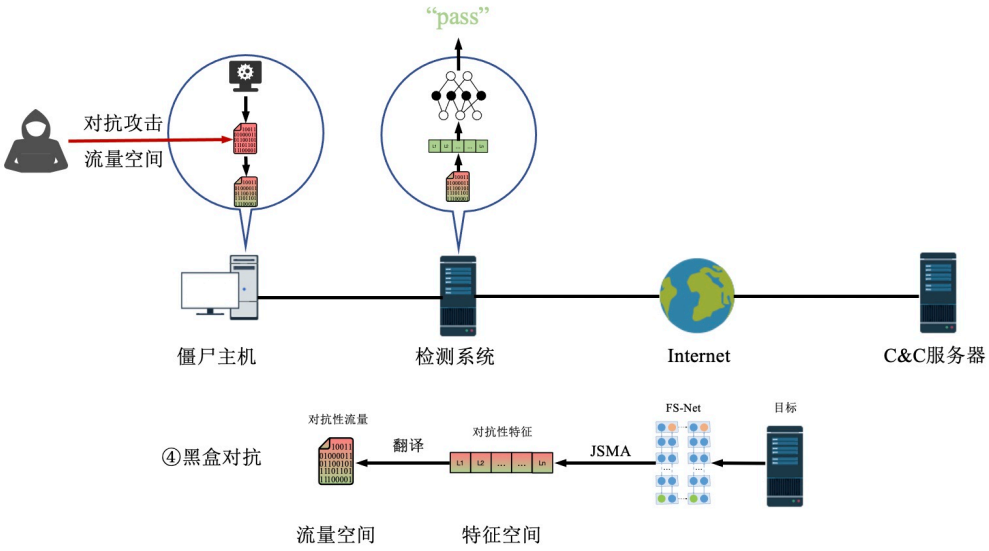


图 4-2 黑盒对抗样本攻击场景

Figure 4-2 Black-box adversarial sample attack scenario

4.3.2 黑盒对抗样本攻击遇到的困难

直观上来讲黑盒对抗样本攻击遇到的困难就是攻击者无法获取目标模型。具体从数学上深入探究的话，按照对抗样本的决策边界理论（如图 4-3 所示）来说，在没有目标模型的情况下，生成对抗样本的算法缺失了决策边界和样本移动方向这两个关键因素。其中决策边界关系着普通样本扰动到什么程度才能够使模型误分类，而样本移动方向则直接决定着对抗样本是否生成成功。

所以黑盒对抗样本攻击面临的困难就是如何在不获取目标模型的情况下，找到一条合适的决策边界用于指导生成对抗样本。

4.3.3 方法动机

前面已经分析了黑盒对抗样本攻击所遇到的困难就是需要找到一条合适的决策边界，用于参与指导对抗样本的生成。基于这样的目标，本文尝试在本地训练一个代理模型，并通过一定的方法使代理模型拥有与目标模型类似的决策边

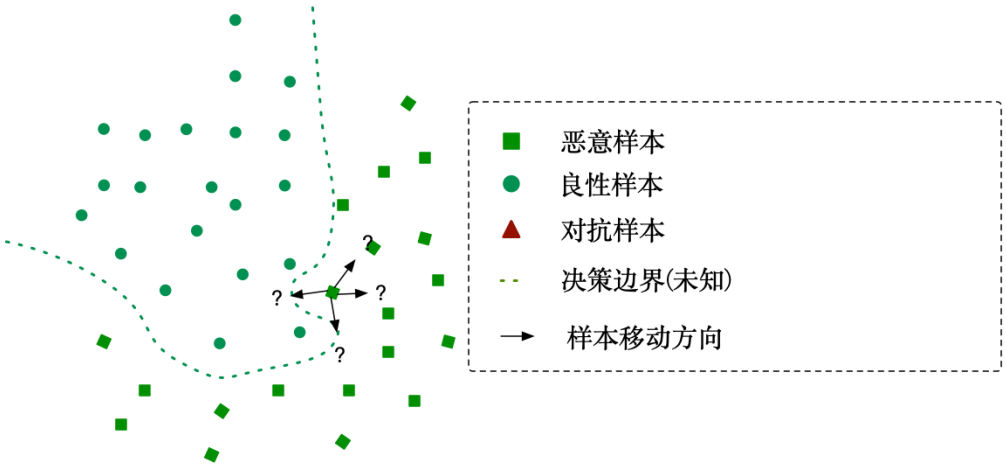


图 4-3 黑盒对抗样本攻击遇到的困难

Figure 4-3 Difficulties in black-box adversarial example attack

界。这样一来，问题就转变成了如何在不知道目标模型细节的情况下，保证代理模型和目标模型有相同或者相似的决策边界。

那么影响机器学习模型决策边界的因素就是决定代理模型好坏的关键。理论分析认为影响机器学习模型决策边界的因素有两个，分别是训练数据的数据分布和机器学习算法的架构，它们影响决策边界的方式如下。

- 数据分布：机器学习模型本质上就是通过拟合训练数据，寻找这个数据分布。对于分类问题来说，这个数据分布的数学表示就是一个超平面（决策边界）。
- 机器学习算法架构：机器学习算法相当于提供一个包含无数个函数的函数集合，训练的目的是从所提供的函数集合中搜索到最优的那一个。不同架构的机器学习模型提供的函数集合范围不一样，越复杂的模型提供的函数集合范围越大，但是复杂模型提供的函数集合在一定程度上会包含简单模型所提供的函数集合，例如深层的前馈神经网络可以拟合任意线性模型，设置能够拟合大部分线性模型。

基于以上描述可以看出，如果有办法获取与目标模型使用的训练集拥有相同或者分布类似的数据，并且使用架构类似或者架构更加复杂的模型作为代理模型，那么就可能找到与目标模型决策边界类似的决策边界，如图 4-4 所示。从图中可以看出，样本在沿着代理模型决策边界的法线方向移动时，会首先穿越代理模型的决策边界，成为能够攻击代理模型的白盒对抗样本，如果继续移动的话，就有可能穿越目标模型决策边界成为黑盒对抗样本。

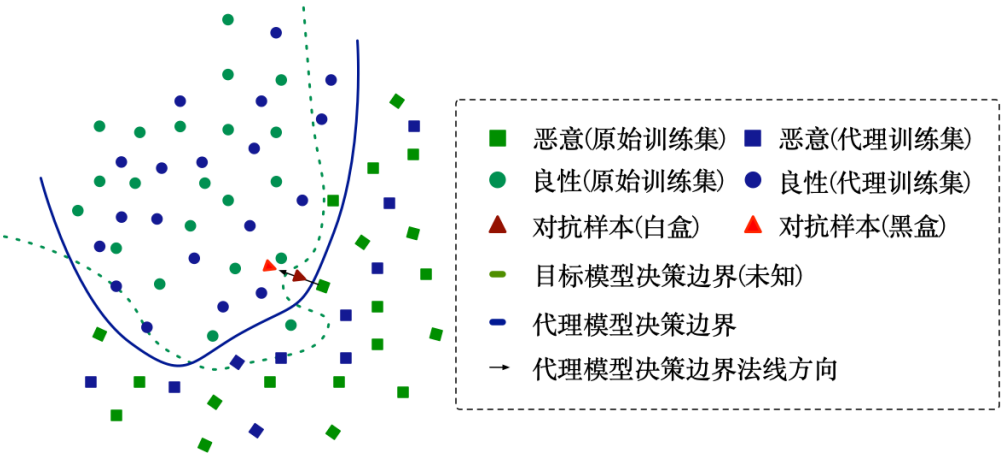


图 4-4 黑盒对抗样本攻击决策边界模型

Figure 4-4 Decision boundary model for black-box adversarial sample attack

4.4 方法阐述

本小节首先给出黑盒对抗样本方法的整体框架，整个方法包含两个大的步骤。第一步，本文首先将一批包含良性和恶意流量的代理训练集样本输入给目标模型并且收集目标模型的输出，然后使用目标模型的输出作为代理训练集的标签，并作为监督信号训练代理模型。第二步，本文在代理模型上执行白盒对抗样本攻击，生成对抗样本用于攻击目标模型。方法的整体框架如图 4-5 所示。

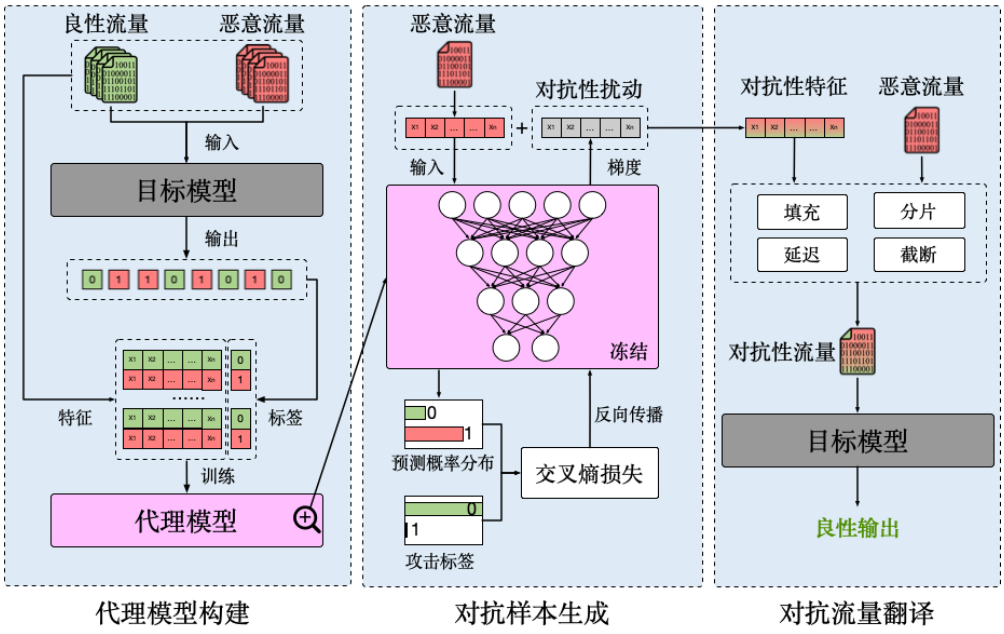


图 4-5 黑盒对抗样本攻击框架

Figure 4-5 Black-box adversarial sample attack framework

4.4.1　代理模型构建

黑盒对抗样本攻击中第一步也是最为关键的一步就是构建一个合适的代理模型。在这个步骤中，本文尽力去构建一个用有与目标模型类似决策边界的代理模型。

首先本文准备一批同时包含良性和恶意的流量数据集 $\mathbb{X}$ 以及他们的真实标签 Y。将第 k 个流量样本 X_k 输入给目标模型 f_t，并收集模型给出的输出结果 $Z_k = \psi_t(\theta; X_k)$。注意这里的输出结果 Z_k 是目标模型对于 X_k 的判别结果，是一个类别标签，并不是目标模型输出的概率分布，这也使得算法实现起来更加的真实。当收集足够多的标签形成一个代理数据集 $\mathbf{X}_p$ 后，就可以使用这个数据集训练代理模型 ψ_p 了。

第二步进行的是使用代理数据集 $\mathbb{X}_p = \{(X_1, Z_1), (X_2, Z_2), ..., (X_n, Z_n)\}$ 来训练代理模型 ψ_p。对于 $\mathbb{X}_p$ 中的第 j 个样本 (X_j, Z_j)，本文将特征向量 X_j 输入给代理模型 ψ_p 并获得其输出 a_j。然后计算 a_j 和 Z_j 的交叉熵损失 (如公式 2-4) 所示。最后使用反向传播算法更新代理模型的参数 θ。整个代理模型的构建过程如算法 1所示。

算法 1 代理模型构建算法

Input: 加密流量样本: $X_k \in \mathbb{X}$; 目标模型: ψ_t; 学习率: lr; 训练轮次: $epoch$; 样本数: N

Output: 代理模型: $\psi_p^* = \arg\min_{\theta \in \psi_p} \mathcal{L}(\psi_p(X), \psi_t(X))$

for $k \leftarrow 1$ **to** N **do**
    $Z_k \leftarrow \psi_t(X_k)$
end for
for $i \leftarrow 1$ **to** $epoch$ **do**
    $L \leftarrow 0$
    for $j \leftarrow 1$ **to** N **do**
        $a_j \leftarrow \psi_p(X_j)$
        $loss \leftarrow -(Z_j \cdot log(a_j) + (1 - Z_j) \cdot log(1 - a_j))$
        $L \leftarrow L + loss$
    end for
    $L \leftarrow \frac{L}{N}$
    $\theta_{i+1} = \theta_i - lr \cdot \frac{\partial L}{\partial \theta_i}$
end for

在实际的攻击场景中，攻击者可以控制受害者主机运行恶意程序并且产生响应的恶意流量，通过这样的方式可以实现自动化的向目标模型发送样本。需要注意的是大多数在线实时恶意流量检测系统都有一定的延迟，所以每两次发送样本之间需要有一定的时间间隔，因此这个步骤在实际攻击场景中会需要大量的时间去收集目标模型的输出结果，但是在实验场景下，本文直接向目标模型输入样本，并不会考虑这个时间间隔。

4.4.2 对抗样本生成

由于代理模型 ψ_p 在攻击者本地进行训练，因此攻击者可以获取代理模型的完整细节。此时，就可以将黑盒对抗样本攻击转化为白盒对抗样本攻击了。

给定一个恶意流量样本 X_m，本文需要将其转化为对抗性恶意流量样本 X_m^{adv}。首先，本文获取代理模型 ψ_p 对于恶意流量样本 X_m^{adv} 的输出 A，然后计算 A 和对抗样本攻击的目标类别标签 Y_b(表示攻击者想要代理模型将 X_M 误分类为良性)的交叉熵损失，最后本文使用反向传播算法更新样本 X_m。本文循环重复这个步骤，直到代理模型将 X_m 判定为良性，此时本文就获取了对抗样本 X_m^{adv}。对抗样本生成的完整过程如算法 2 所示。

算法 2 对抗样本生成算法

Input: 代理模型: ψ_p; 恶意未扰动样本: X_m^c; 缩放率: α; 扰动限制: ϵ; 最大循环次数: $epoch$;
Output: 对抗性恶意流量样本: X_m^{adv}

$X_m^{adv} \leftarrow X_m$
$A \leftarrow \psi_p(X_m^{adv})$
$num \leftarrow 0$
while $A \neq Y_b$ and $num \leq epoch$ **do**
    $loss \leftarrow -(Y_b \cdot log(A) + (1 - Y_b) \cdot log(1 - A))$
    $\eta \leftarrow \frac{\partial loss}{\partial X_m^{adv}}$
    $X_m^{adv} \leftarrow X_m^{adv} + \alpha \cdot \eta$
    $X_m^{adv} \leftarrow clip(X_m^{adv}, \varepsilon)$ **s.t.** $d(X_m^c, X_m^{adv}) \leq \varepsilon$
    $A \leftarrow \psi_p(X_m^{adv})$
    $num \leftarrow num + 1$
end while

在算法 2 中需要特别注意两个点。首先，与代理模型的训练过程不同，对抗样本生成过程中需要固定代理模型的参数 θ，使用交叉熵损失反向传播会恶意样本的梯度来修改恶意样本。其次，对抗性扰动需要控制在一定的扰动幅度之内，算法中控制扰动幅度的是 ϵ，如果扰动幅度过大会导致样本无法翻译成为对抗性流量。本文这里使用的是无穷范数作为距离函数来计算对抗性扰动的幅度。

4.5 实验评估

本节的实验主要包含两个部分：首先搜索算法 1 和算法 2 以及整个攻击过程中涉及到的一些超参数，并且探究每个超参数对攻击的影响；第二部分是通过实验验证本文所提出的黑盒对抗样本攻击的有效性。

本章实验所用到的数据集、特征集合、目标模型和代理模型等实验设置沿用第 3 章中的设置，本节中所有实验使用的数据集是 MTA 数据集。

4.5.1　对抗性扰动幅度限制 ϵ 的影响

与其他所有的流量扰动方法一样，对抗样本攻击同样需要在扰动幅度和绕过率之间做一个平衡。为了搜寻最优的扰动幅度，本文设计了下述实验。

首先，当目标模型和代理模型均使用 FS-Net 的时，对抗样本攻击的绕过率 EDR 随扰动幅度 ϵ 的变化如图 4-6a 所示。对于 MTA 数据集中的所有恶意软件家族，对抗样本的检测逃逸率都在随着扰动幅度的变大在增大。当扰动幅度 $\epsilon = 0.3$ 时，所有恶意家族的对抗样本的检测逃逸率都超过了 90%。

从图 4-6a 中可以观察到的规律就是对抗样本的检测逃逸率随扰动幅度的变化在代理模型上和目标模型上呈现相似的变化规律。所以攻击者在一定程度上可以利用代理模型的反馈对超参数 ϵ 进行调整，直至获得最佳 ϵ。

此外，图 4-6b 展示了在面对不同目标模型时，对抗样本的检测逃逸率随着扰动幅度的变化情况。以 TrickBot 为例，当代理模型使用 LSTM 并且扰动幅度 $\epsilon = 0.1$ 时，对抗样本对于所有的基于神经网络的目标模型（例如 FS-Net、DNN 和 LSTM）都有比较好的检测逃逸率；但是这些对抗样本对于非神经网络类的目标模型（例如 LR 和 SVM）的检测逃逸效果较差。但是即使代理模型和目标模型的架构差别非常大，但是当 $\epsilon = 0.3$ 时，对抗样本对于这些非神经网络模型的检测逃逸率也是可以接受的。

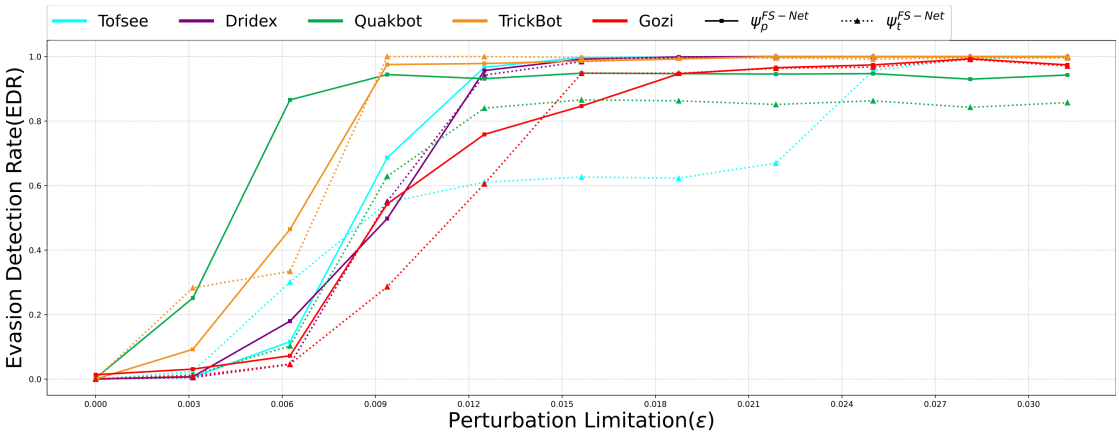
出现图 4-6b 这种现象的原因是代理模型的架构和目标模型的架构差别太大，按照前面的决策边界理论来解释的话，基于神经网络的模型所提供的函数集合与非神经网路的模型提供的函数集合差别太大，导致代理模型无法找到合适的决策边界，后面的实验会深入探究。另一方面，算法 2 中使用交叉熵损失反向传播到样本的梯度去更新样本，而传统的非神经网络模型并没有使用到反向传播的方式，或者或传统机器学习的最优化方法并不是梯度下降算法，导致生成的对抗样本在一定程度上检测逃逸率会有下降。

扰动幅度的提高能够有效的增加对抗样本的检测逃逸率，但是过大的扰动幅度会破坏恶意流量本身的属性，增加后续流量翻译过程的困难度。因此扰动幅度是一个需要平衡的超参数，攻击者需要在生成对抗样本困难度和对抗样本的攻击有效性之间做一个平衡。经过上述实验的探究，本文后续所有实验中扰动幅度均取 $\epsilon = 0.1$。

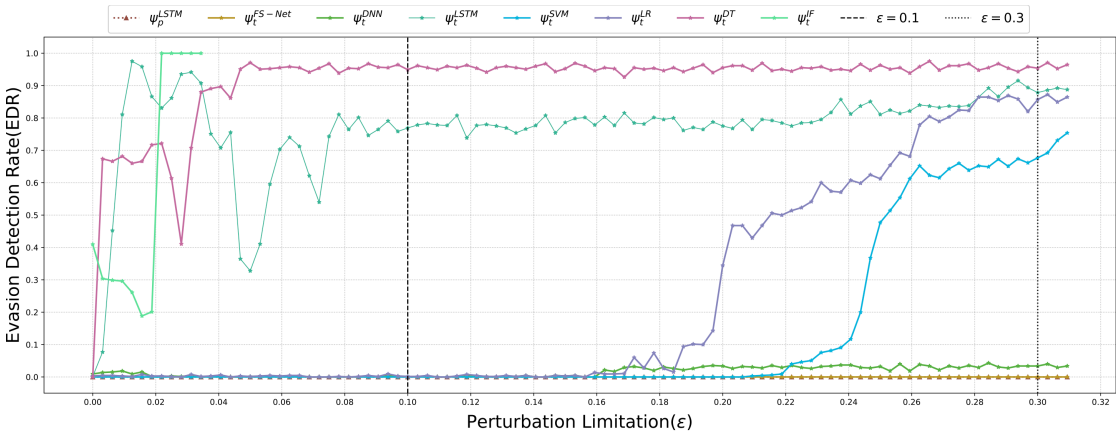
4.5.2　代理模型训练集数量的影响

在代理模型构建之初，本文通过目标模型的输出来标定样本，并且认为这样收集到的数据集的数据分布与目标模型的训练集的数据分布不是类似的。需要考虑一个比较关键的因素就是这个训练代理模型的数据集的数量。如果代理训练集样本数量过少，可能会导致代理模型出现过拟合的现象，拟合出的函数形成的决策边界与目标模型相差较大，这样就会大幅降低对抗样本的检测逃逸率。

在扰动幅度为 $\epsilon = 0.1$ 时，本文分别使用不同数量的样本去训练代理模型 (这里使用的依然是 LSTM 模型) 并生成对抗样本，对抗样本对 FS-Net 模型的检测



(a)



(b)

图 4-6 对抗样本绕过率 (EDR) 随扰动幅度 (ϵ) 变化 (a) 展示不同的恶意软件家族 (b) 展示不同的目标模型

Figure 4-6 The evasion effectiveness of the adversarial traffic with different ϵ (a) shows different malware families(b) shows different target architectures

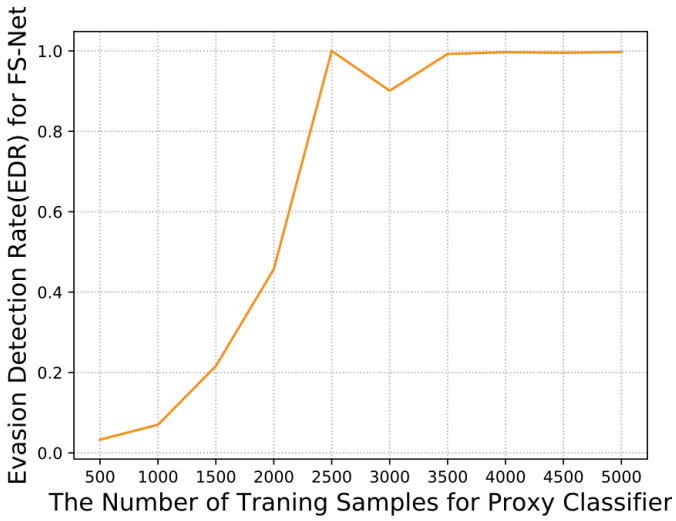


图 4-7 对抗样本检测逃逸率随着训练样本数量的变化

Figure 4-7 The evasive effectiveness of adversarial traffic with different number of training samples

逃逸率随着训练样本数量的变化规律如图 4-7 所示。

从实验结果可以总结出以下规律：代理模型构建阶段收集到越多的数据，最终生成的对抗样本的检测逃逸率越高。收集这些数据是一个十分耗时的工作，需要攻击者在时间成本和攻击成功率之间做一个平衡。为了达到更好的攻击效果，本文全部收集到的目标模型反馈数据用于训练代理模型。

4.5.3　代理模型架构的影响

通过前面的理论分析影响机器学习模型决策边界的关键因素有两个，其中之一就是机器学习模型的架构，本小节以及下一小节就通过实验探究一下这个因素对于生成的对抗样本的影响。

为了探究对抗样本在不同架构的模型之间的可转移性，本文使用了三种架构的代理模型 (DNN、LSTM 和 FS-Net）以及 7 种不同架构的目标模型 (DNN、FS-Net、LSTM、LR、DT、SVM 和 IF) 执行了 45 组实验。同时为了探究不同和特征类型对于对抗样本可转移性的影响，本文在两个数据集上提取了包括统计特征和序列特征在内的两种类型的特征进行实验。值得说明的是由于 FS-Net 是为了序列特征设计的，所以 FS-Net 没有参与统计特征的相关实验。

表 4-2 对抗样本在不同架构模型之间的可转移性

Table 4-2 Transferability of adversarial traffic between classifiers with different architectures

Feature Type	Proxy Classifiers(ψ_p)	EDR against Target Classifiers(ψ_t)						
		DNN	FS-Net	LSTM	LR	DT	SVM	IF
Sequence Features	MLP	**65.62**	32.84	27.43	20.63	15.10	0.46	**49.06**
	FS-Net	8.90	**99.94**	**96.19**	30.03	**100**	0.46	21.36
	LSTM	7.06	96.68	82.58	**42.26**	71.63	0.55	24.136
Statistical Features	DNN	**69.05**	-	41.67	**72.96**	**63.69**	**51.03**	**21.74**
	LSTM	34.62	-	**75.97**	38.52	50.48	34.84	0.89

当扰动幅度 $\epsilon = 0.1$ 时，整体的实验结果如表 4-2 所示，对该实验结果的分析如下。当代理模型和目标模型使用相同的算法架构时，即便他们使用不同的超参数和内部参数，对抗样本依然可以取得较高的检测逃逸率，比如当代理模型和目标模型都是 FS-Net 时，对抗样本的检测逃逸率高达 99.94%。当代理模型架构和目标模型架构不同但是相似时，例如 FS-Net 和 LSTM，对抗样本的检测逃逸率也高达 96.19%。如果代理模型和目标模型的架构完全不同时，例如代理模型是 LSTM 但是目标模型是 IF 时，检测逃逸率就非常低。因此可以总结出规律：对抗样本在架构越相似的模型之间的转移效果越好，选择与目标模型架构越相似的代理模型生成的对抗样本检测逃逸率越高。

在机器学习的理论中，模型架构相当于提供一个包含了无数个函数的函数集合，而训练过程本质上就是一个最优化的过程，从模型提供的函数集合中搜索到最右的那个函数。所以架构越相似的模型提供的函数集合交集也就越大，代理模型也就更有可能搜寻出与目标模型相同的函数。另一方面，使用复杂架构的代

理模型比简单架构的代理模型效果要好，因为复杂模型所包含的函数集合更大，更有可能包含与目标模型相同或者相似的决策函数。

经过上述实验及分析，本文后续实验代理模型选择如下：对于序列特征而言，使用 FS-Net 作为代理模型；而对于统计特征而言，使用 DNN 作为代理模型。

4.5.4 目标模型使用特征类型的影响

从表 4-2 中的实验结果还可以总结出另一个规律：对抗样本在使用相似特征的模型之间的可转移性更好。例如，如果代理模型使用 DNN 的话，对抗样本针对使用统计特征的目标模型的检测逃逸率明显高于使用序列特征的目标模型。这是因为因为 LSTM 和 FS-Net 等模型都是基于循环神经网络的模型，这类模型更加擅长处理序列特征，能够挖掘出序列特征中的上下文中关联信息，而传统的机器学习模型对于序列特征的处理能力较差。同时另一方面，传统机器学习模型更加擅长处理基于统计特征的模型，这点和 DNN 非常相似。

本文使用决策边界理论来解释代理模型架构和特征类型对于对抗样本的影响。模型架构和训练数据集是影响模型决策边界的两个重要因素，所以代理模型的架构自然会影响对抗样本生成的精度。而不同类型特征形成的训练集内涵的数据分布肯定是不一致的，例如包长序列特征的每个包长都是一个从 0 到 1500 的整数，而如果是统计特征的话就完全不一样了，每个特征的阈值都不一样，甚至可能有点特征是离散值，因此目标模型使用的特征类型也是攻击者极力需要了解的信息。但是在黑盒攻击的假设下，攻击者是不太可能精确得了解到目标模型使用到何种特征，所以代理模型使用的特征集合就是一个很大的问题。

对于对抗样本选择什么特征进行对抗，结合 3.3 中的评估结果，可以得出如下的结论。第一，选择对分类结果贡献度较高的特征，因为特征对分类结果的贡献度越高，该特征则会被越多的检测模型使用。第二，选择对抗显著性较高的特征，因为对抗效果越显著，就可以在越小的成本下实现对抗，提高对抗样本的检测逃逸率。

4.5.5 对抗样本攻击有效性

基于上述实验的观察和发现，对抗样本攻击有效性的实验设置如下。对于序列模型，本文选用 FS-Net 作为代理模型，并且对于统计特征本文选用 DNN 作为代理模型进行实验。本文分别计算四种传统机器学习模型和三种基于神经网络的模型的检测性能，然后计算对抗样本对于这些检测模型的检测逃逸率。

当扰动幅度限制在 $\epsilon = 0.1$ 时，实验结果如表 4-3 所示。当目标模型使用序列特征时，FS-Net 代理模型产生的对抗样本对 LSTM 和 FS-Net 等目标模型的检测逃逸率超过了 96.2%，但是在 DNN、LR、SVM 和 IF 上的检测逃逸率则较差。对抗样本对于 DT 的检测逃逸率看起来比较奇怪，不符合之前的分析，主要是因为树相关的分类器没有使用类似距离或者密度等指标来刻画样本之间的亲疏关系，只要修改一个合适的特征就可以改变分类结果。所以对于使用序列特征的

DT 模型来说，对抗样本的攻击效果是相对较好的。

表 4-3 目标模型检测性能及对抗样本检测逃逸率

Table 4-3 Detection effectiveness of target classifiers and evasing effectiveness of adversarial traffic

Target Classifier(ψ_t)	Sequence Features(ψ_p =FS-Net)				Statistical Features(ψ_p = DNN)			
	Detection			Evasion	Detection			Evasion
	P	R	F1	EDR	P	R	F1	EDR
DNN	97.78	98.43	98.11	8.90	94.84	95.00	94.80	**69.05**
FS-Net	99.98	99.98	99.98	**99.94**	-	-	-	-
LSTM	96.88	97.09	96.85	**96.19**	94.40	94.47	94.35	41.67
LR	99.75	99.87	99.81	30.03	89.75	99.06	94.09	**72.96**
DT	100	100	100	**100**	99.61	99.53	99.57	63.69
SVM	99.85	98.99	99.42	0.46	96.43	99.24	97.77	**51.03**
IF	82.84	52.71	64.35	21.36	76.54	48.22	59.16	**21.74**

当目标模型使用统计特征时，由 DNN 作为代理模型产生的对抗样本对于大部分传统机器学习模型（除了 IF 外）都有超过 50.5% 的检测逃逸率，原因是 IF 不同于其他模型，不使用距离或密度等指标来描述一个样本与其他样本的差异，因此在小范围内修改特征可能对 IF 效果不佳。

4.6　本章小结

本章主要介绍了基于对抗样本可转移性的黑盒对抗样本攻击方法，并通过实验探究了影响对抗样本可转移性的因素以及黑盒对抗样本攻击的有效性。基于对抗样本的决策边界理论，本文训练出与目标模型拥有相似决策边界的代理模型，并用该代理模型生成对抗样本，从而避免需要攻击者直接获取目标模型，实现了黑盒对抗样本攻击。本文的实验证明了代理模型架构、代理模型训练数据、目标模型使用特征、对抗样本扰动幅度四个因素是影响黑盒对抗样本攻击成功率的关键因素。最后的攻击有效性实验表明了在最佳参数情况下，基于对抗样本可转移性的黑盒对抗样本攻击可以实现有效的检测逃逸，具有一定的实际意义。

基于对抗样本可转移性的黑盒对抗样本攻击方法的意义有两个方面。第一，本方法在完全不获取目标模型的情况下实现了对目标模型的规避攻击，这对现有基于机器学习的恶意流量检测模型的安全性带来了极大的挑战，在一定程度上能够引起安全社区对于对抗样本攻击防御工作的重视，同时也会促进之后的恶意流量检测模型加入对抗防御的设计。第二，本方法提出了解释对抗样本攻击的决策边界模型，并通过实验探索了影响对抗样本可转移性的几个关键因素，这给对抗样本攻击的理论解释提供了一定的实验支撑。

第 5 章　基于流量扰动的对抗性流量翻译方法

5.1　引言

本章针对现有基于特征空间的对抗样本难以转化为具有实际意义的对抗性流量的问题，提出了基于流量扰动的对抗性流量翻译方法，将对抗性特征通过流量扰动的方式翻译成为具有对抗性的合法流量。基于特征空间的对抗样本攻击扰动的对象是特征向量，虽然检测逃逸效果会更好，但在实际场景下攻击者却很难直接特征向量。因为特征向量是恶意流量检测系统生成的中间产物。因此本章通过将针对不同类型的对抗性特征提出不同的流量扰动算法，形成具有实际攻击意义的对抗性流量，提高对抗样本攻击的实际意义。

本章提出基于流量扰动对抗性流量翻译方法。针对于包长相关的特征，提出流量包长扰动算法，通过包填充和包插入的方式修改流量的包长特征；针对时间相关的特征，提出流量时间扰动算法，通过缓冲并延迟发送的方式修改流量的时间特征。最终的对比实证明本章所提方法的有效性，在仅修改包长特征和时间特征的情况下，本方法的检测逃逸率比最先进的黑盒对抗方法高 29.9%。最后，本文通过 PCA 算法将高维空间中的特征压缩到二维空间，直观的展示了对抗样本在空间中的分布，解释了对抗样本使机器学习模型误分类的原因，并直观的展示了对抗样本的可转移性。

本章将按照如下结构进行组织。5.2 节介绍了与流量空间对抗样本攻击有关的一些概念；5.3 节定义了本章需要解决的问题以及解决这些问题所遇到的困难；5.4 节详细的阐述了本章所提出的方法；5.5 节通过大量的实验评估了本方法的有效性；5.6 节通过可视化的方式，直观的展示了对抗样本在空间中的分布；最后5.7 节对本章进行小节。

5.2　问题背景

5.2.1　特征空间与流量空间

在2.1 节中介绍到，使用机器学习进行恶意流量检测的整体流程分为特征提取和算法分析（异常检测）两个大的步骤。特征提取模块的直接输入是原始的计算机网络流量，从网络流量所构成的数据空间中进行特征提取，输出的是预定义好的格式化特征向量；而算法分析模块接受的输入则是特征向量，在特征向量所构成的数据空间中进行异常检测，最终输出样本属于良性还是恶意的判断。数据在恶意流量检测系统中的流转过程如图 5-1 所示。

因此对基于机器学习的恶意流量检测模型进行对抗样本攻击的话，就存在两个可以实施对抗性扰动的数据空间（如图 5-2 所示）。分别是：

- 特征空间：由特征向量组成的高维数据空间，例如由 CICFlowMeter 提取的特征向量组成的 77 维空间。在对抗样本攻击中，如果攻击者扰动的样本数据

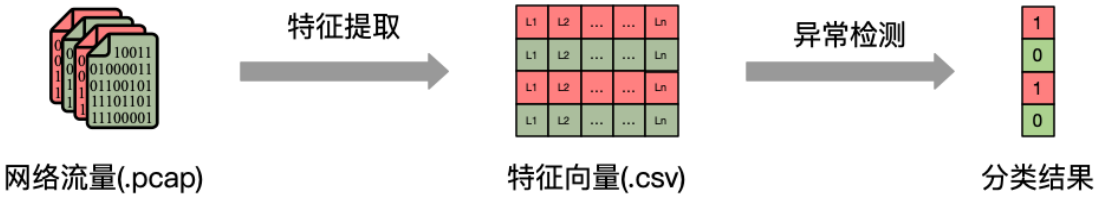


图 5-1 基于机器学习的恶意流量检测模型数据流向

Figure 5-1 The data flow in ML-based malicious traffic detector

是特征向量的话，则称为基于特征空间的对抗样本攻击。

- 流量空间：由原始计算机网络流量组成的空间，由于流量数据结构不固定，长度不固定，形成的数据空间也更加复杂。在对抗样本攻击中，如果攻击者扰动的样本数据是原始流量，则称为基于流量空间的对抗样本攻击。

从定义中可以看到，基于特征空间的对抗样本攻击需要攻击者直接扰动原始的特征向量，而在如图 5-2 所示的场景中，特征向量是检测系统的中间产物，在实际攻击场景中攻击者是难以直接修改特征向量的。而基于流量空间的对抗样本攻击则更加实际，因为攻击者可以控制僵尸主机，修改原始的恶意软件通信流量。

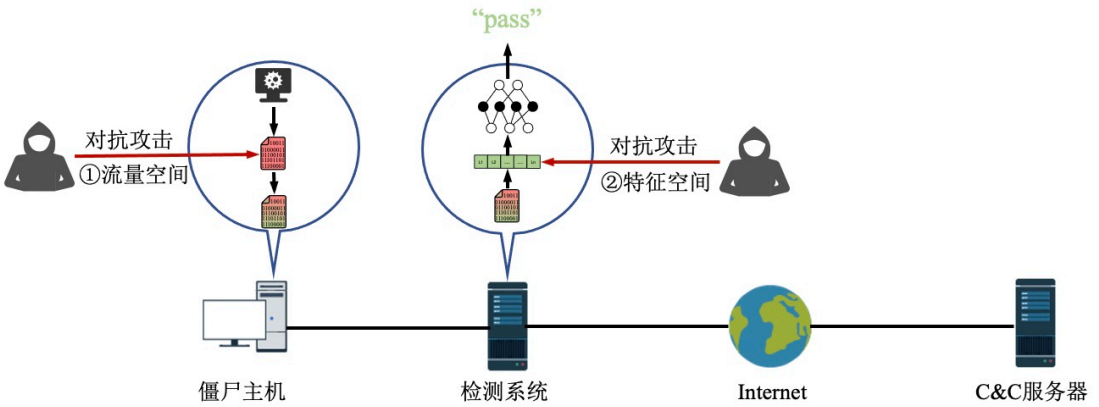


图 5-2 基于特征空间与流量空间的对抗样本攻击

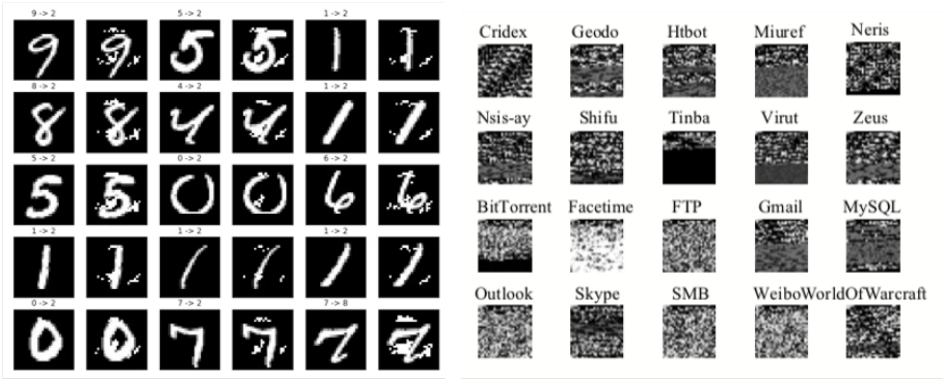
Figure 5-2 Adversarial example attack based on feature space and traffic space

5.2.2 基于流量空间的对抗样本攻击方法的特殊性

对抗样本攻击技术起源于计算机视觉社区的，将这些方法直接用于恶意流量检测领域的话会遇到许多的问题。

首先是数据的不同（如图 5-3 所示）。对于一个图像识别模型来说，图像本身就是一组结构化的特征向量。图像这种结构结构化的特性使得研究者可以专注于研究对抗分类模型的算法，而不用过多的去考虑数据预处理的问题。攻击者通过各种方法计算出了对抗性扰动之后可以直接将扰动加载原始的图像上就形成了对抗样本，而对抗样本也直接可以输入给目标模型。但是网络流量数据则更

加的复杂，网络流量是一种由计算机网络协议自动产生的数据，虽然从严格意义上讲流量数据是结构化的，但是由于计算机网络协议经过多年的发展，导致流量数据的结构是十分复杂的。



(a)　　(b)

图 5-3 图片数据与流量数据对比

Figure 5-3 Comparison of image data and traffic data

其次是两个领域的检测流程不一样。大多数分析网络流量的系统都需要将原始的流量预处理成为结构更为简单，形式更加单一的结构化数据，然后再进行分析。流量的预处理过程是一个不可逆的步骤，即从流量数据到特征向量的过程是不可逆的。因此在对流量检测系统进行对抗样本攻击时，不得不考虑流量预处理的过程。而图像检测的话图片数据可以直接输入到算法模型中，中间没有经过预处理的步骤。

最后就是两个领域的检测算法不一样。图像领域的大部分检测模型都是基于神经网络模型，而流量检测系统除了神经网络模型，也有很大一部分基于传统机器学习模型和一些统计学习方法。流量数据的特殊性导致了来自于图像领域的对抗样本攻击方法不在适用，也就催生出了研究面向恶意流量的对抗样本攻击方法的需求。

5.3　问题定义

5.3.1　威胁模型

在一个基于流量空间的对抗样本攻击场景中，涉及的三个实体依然还是攻击者，受害者和检测者（见 4.3 节）。为了实现流量空间的对抗样本攻击，攻击者除了在受害者主机上部署恶意软件外，还会部署相应的流量翻译程序，用于扰动恶意软件生成的恶意流量，形成具有对抗性的恶意流量。同时也会在 C&C 服务器端部署相应的流量解译程序，恢复原始的恶意流量并且保证恶意流量的上行流量和下行流量都是具有对抗性的。

在对抗性流量攻击中，数据流向如图 5-4 所示。恶意软件客户端生成的应用数据会被流量翻译程序拦截，然后由流量翻译程序将原始的恶意流量与事先计

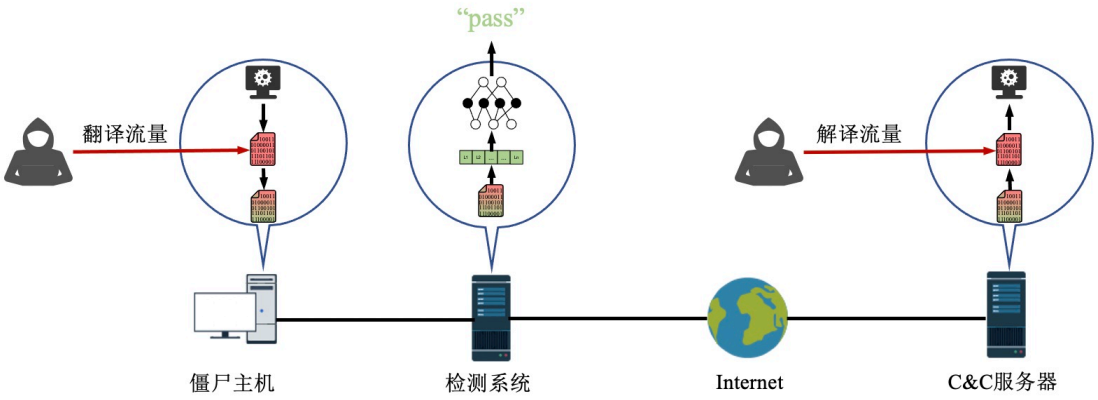


图 5-4 基于流量空间的对抗样本攻击

Figure 5-4 Traffic space based adversarial example attack scenario

算好的对抗性扰动相结合形成了具有对抗性的恶意流量，之后再通过网卡发送到受害主机外部。同时 C&C 服务器端发送的流量也会被流量解译器进行解译，删除一些用于填充的字节，并且翻译服务器发送的响应数据，从而保证整条流的上行数据和下行数据都是具有对抗性的。而恶意流量检测系统由于捕获的是具有对抗性的恶意流量，并不会产生告警。这样恶意流量就成功的绕过了恶意流量检测器的检测，实现了对抗样本攻击。

具体而言，在给定一条恶意流量 T_m 后，对抗样本攻击需要将其转化为具有对抗性的恶意流量 T_m^{adv}，使得恶意流量检测模型不对其产生告警 $f_t(\theta;T_m^{adv}) \rightarrow Y_b$。第 4 章通过实验证明了所提出的黑盒对抗样本方法能有效的规避大部分基于机器学习的恶意流量检测器的检测，即已经成功的实现从 $f_t(\theta;X_m^{adv}) \rightarrow Y_b$ 的过程，而距离 $f_t(\theta;T_m^{adv}) \rightarrow Y_b$ 的目标只差一步，就是从对抗性特征到对抗性流量的过程 $f(X_m^{adv},T_m) \rightarrow T_m^{adv}$，本文将这一个过程称为流量翻译。

5.3.2 流量翻译过程中遇到的困难

在流量翻译的过程中遇到的困难在于需要保证翻译后流量具备三个性质。

(1) 保证流量的合法性：经过翻译后的流量必须是符合计算机网络协议规范的合法流量，即能够被其他网络设备正常的读取、转发和解析等。如果破坏流量的合法性，不仅失去了对抗的意义，甚至会导致恶意软件本身无法进行正常通信。

(2) 保证流量的对抗性：经过翻译后的流量应该保持对抗样本的对抗性质，即流量被检测系统捕获后，能够成功的使检测模型生成错误的分类结果，这是对抗性流量攻击能够成功最关键的一点，也是最为困难的一点。

(3) 保证流量的恶意性：经过翻译后的流量应该保持原始恶意流量的恶意性，即不能够破坏恶意软件原本的功能，例如 DDoS 攻击流量一般不能够修改其发包速率，因为一旦将发包速率改小，虽然能够成功的绕过检测器，但是就失去了 DDoS 攻击的目的。

5.4　方法阐述

5.4.1　流量特征分类

表 5-1 特征总结

Table 5-1 Summary of features

	统计特征				序列特征
	No.	Name	Attributes	Direction	Name
时间相关	0	Flow duration	-	Both	Time interval sequence
	15-28	Time between two packets	Avg, Std, Max, Min	Both	
			Sum,Avg,Std,Max,Min	Fwd	
			Sum,Avg,Std,Max,Min	Bwd	
	69-76	Active time	Avg, Std, Max, Min	Both	
		Idle time	Avg, Std, Max, Min	Both	
包长相关	1-12	Packet Count	-	Both	Packet length sequence
		Total length	-	Fwd,Bwd	
		Packet length	Avg, Std, Max, Min	Fwd,Bwd	
	37-41	Packet length	Avg,Std,Max,Min,Var	Both	
其他	13-14 50-68	Rate	-	-	-
	29-36 42-49	TCP Flag	-	-	

本文使用的流量特征如 3-2 所示，在之前的实验中，本文根据目标模型从原始流量中提取特征的方式不同将流量分为统计特征和序列特征。本节为了方便进行流量翻译，按照特征提取的位置不同，将流量特征划分为与时间相关的特征、与包长相关的特征和其他特征，如表 5-1 。

- 与时间相关的特征：所有需要统计数据包时间的特征及从这些特征推导而出的流量特征，例如与发包间隔，平均发包间隔，发包间隔的方差等。
- 与包长相关的特征：所有需要统计包长的特征以及从这些特征推导而出的特征，例如平均包长，最大最小包长等。
- 其他特征：例如 TCP Flag 等修改后会破坏流量合法性的特征。

需要注意的是这种分类方式划分的特征并不互斥，例如流速这个特征，是从包长总和除以总时长，所以既属于与时间相关的特征有属于与包长相关的特征。

5.4.2　流量包长扰动算法

针对与包长相关的特征，可以使用如下的方式进行修改。

- 包填充(Packet Padding)：如算法 3 所示，给定原始恶意流量 $T_m = [p_1, p_2, ..., p_{n1}]$，以及对抗性包长序列 $X_{adv} = [l_1, l_2, ..., l_{n2}](n1 \geq n2)$，通过向每个数据包应用层的末尾填充无意义的数据（例如 0x00）来增加包的长度，最终生成具有对抗性的恶意流量 $T_m^{adv} = [p_1', p_2', ..., p_{n2}']$。当 C&C 服务器接收到这些数据时，可以将这些数据丢弃，填充操作是不影响流量的合法性的。但是需要注意的是填充操作只可以增大数据包的包长，而不能减少数据包的包长。

算法 3 流量包长扰动算法

Input: 恶意流量: $T_m = [p_1, p_2, ..., p_{n1}]$; 恶意流量长度: $n1$; 对抗性包长序列: $X_{adv} = [l_1, l_2, ..., l_{n2}]$; 对抗性包长序列长度: $n2$

Output: 对抗性恶意流量: $T_m^{adv} = [p_1', p_2', ..., p_{n2}']$

$j \leftarrow 1$
for $i \leftarrow 1$ **to** $n1$ **do**
  if $i \geq n2$ **then**
    BREAK
  end if
  $l_i \leftarrow X_m^{adv}[i]$
  if $\text{len}(p_i) \leq l_i$ **then**
    $p_i \leftarrow T_m[j]$ ▷ 包填充
    $p_i' \leftarrow p_i \oplus \{0x00 \times (l_i - \text{len}(p_i))\}$
    $X_m^{adv}[i] = p_i'$
    $j \leftarrow j + 1$
  else
    $p_i' \leftarrow \{0x00 \times l_i\}$ ▷ 包插入
  end if
  $X_m^{adv}[i] \leftarrow p_i'$
end for

- 包插入（Packet Insertion）：如算法 3 所示，对抗样本算法计算出的包长长度小于原始包长，算法会填充一个包含所有无意义数据的虚拟数据包，虚拟数据包的应用层数据全都由 0x00 组成。

算法 4 流量时间扰动算法

Input: 恶意流量: $T_m = [p_1, p_2, ..., p_{n1}]$; 恶意流量长度: $n1$; 对抗性时间间隔序列: $X_{adv} = [t_1, t_2, ..., t_{n2}]$; 对抗性包长序列长度: $n2$

Output: 对抗性恶意流量: $T_m^{adv} = [p_1', p_2', ..., p_{n2}']$

$Q \leftarrow [p_2, p_3, ..., p_m]$
$t1 \leftarrow T(p_1)$ ▷ $T(p_i)$ 表示获取 p_i 的时间戳
$T_m^{adv}[0] \leftarrow p_1$
$i \leftarrow 0$
while Q 非空 **do**
  $p \leftarrow Q.pop()$
  $t_i \leftarrow X_m^{adv}[i]$
  $p.timestamp \leftarrow t2 + t_i$ ▷ 设置定时器在固定时间发送数据包
  $X_m^{adv} \leftarrow p$
  $t2 \leftarrow t2 + t_i$
  $i \leftarrow i + 1$
  $Q \leftarrow Q \oplus T_m[i]$
end while

5.4.3　流量时间扰动算法

针对与时间相关的特征，可以使用如下的方式进行修改。

- 缓冲发送（Buffer）：如算法 4 所示，给定原始恶意流量 $T_m = [p_1, p_2, ..., p_{n1}]$，以及对抗性的时间间隔序列 $X_m^{adv} = [t_1, t_2, ..., t_{n2}]$。缓冲前 m 个数据包，然后将缓冲队列中的数据包按照 X_m^{adv} 中的要求去发送，最终形成在时间间隔序列上具有对抗性的恶意流量 $T_m^{adv} = [p_1', p_2', ..., p_{n2}']$。

5.5　实验评估

为了方便进行对比实验，本章实验评估使用的数据集为 CICIDS2017 数据集，其他的实验设置与 3.2 节一致。

5.5.1　对比实验

为了充分验证本文所提方法的有效性，本文设置了丰富的对比实验将本方法与目前最优秀的白盒与黑盒对抗性流量攻击方法进行对比。基础方法和对比方法如下所示。

- 基础方法（Baseline）：流量的对抗样本攻击属于流量扰动的一种，所以用简单的流量扰动方法（例如添加随机噪声）作为基础方法进行对比。本文使用的是 Stinson 等[55] 所提出的方法，在一定程度上也具有对抗性。其中 R-T（Random Time）表示在数据包之间随机插入时间间隔；R-D（Random Duplicate）表示随机复制原始流量。
- 白盒方法（White-box）：Hashemi 等[21] 首次将对抗样本攻击引入网络入侵检测系统（Intrusion Detection System, IDS）中。他们假设攻击能够获取目标模型的全部信息并设计了一个对抗样本攻击方法用于攻击目标 IDS。
- 黑盒方法（Black-box）：Han 等[22] 基于生成对抗网络（Generative Adversarial Network, GAN）设计了一个黑盒对抗样本攻击方法，并使用 CICIDS2017 数据集评估他们的方法[1]。

此外，为了增加所提出方法的实用性，本文还设计了四种特征扰动受到限制的场景，分别是:

- 所有特征（A）：所有特征均可被修改。其中与时间相关特征和包长相关特征通过算法 3 和算法 4 在流量空间进行修改。其他特征例如 TCP Flag 等则在特征空间进行修改。
- 时间特征（T）：在流量空间使用算法 4 修改与时间相关的特征。
- 包长特征（L）：在流量空间使用算法 3 修改与包长相关的特征被算法修改
- 时间特征 + 包长特征（T + L）：在流量空间同时修改与时间相关的特征和包长相关的特征。

[1]Baseline、White-box 和 Black-box 方法的实验数据为论文[22] 中表 7 中 Botnet 和 DDoS 数据的平均值

实验选用 DNN 作为代理模型，对抗样本扰动幅度 $\epsilon = 0.1$，选用 5 种不同的目标模型，最终的对比实验结果如表 5-2 所示。

表 5-2 对比实验结果 (ψ_p = DNN, $\epsilon = 0.1$)

Table 5-2 Comparative Experimental Results(ψ_p = DNN, $\epsilon = 0.1$)

Target	Detection			Comparison Attack				Our Method			
	P	R	F1	EDR				EDR			
				R-D	R-T	White-box	Black-box	A	T	L	T+L
DNN	99.62	98.52	99.16	12.96	7.15	27.03	47.89	94.89	73.99	58.37	**95.02**
LR	99.46	94.54	96.92	13.88	15.73	57.54	62.67	84.83	59.41	74.39	**80.38**
DT	99.88	99.86	99.87	14.02	15.90	56.70	65.11	99.99	100	100	**99.99**
SVM	99.41	96.47	97.71	15.39	13.65	33.89	59.93	99.63	81.86	65.59	**92.78**
IF	90.72	57.45	70.46	0.38	6.58	0.26	25.67	54.19	44.11	10.32	**55.33**
AVG	97.82	89.37	92.82	11.33	11.80	35.08	52.25	86.71	71.35	61.73	**82.12**

5.5.2 对比实验结果

由于部分统计特征（例如 TCP Flag 等）无法被有效翻译为对抗性流量，所以第一组实验（Our Method-A）仅在特征空间进行对抗。而其他针对时间特征和包长特征的三组实验均可以利用算法 3 和算法 4 将对抗性特征转化为对抗性流量，所以第二组到第四组实验在流量空间进行对抗。

从表 5-2 所示的对比实验结果中可以看到，当所有的特征都可以被随意修改时，本文方法取得了平均 86.7% 的检测绕过率，这比目前最好的黑盒对抗样本方法高 34.4%。即使只有时间相关的特征或者包长相关的特征可以被修改时，本文方法也可以分别取得 71.3% 和 61.7% 的检测绕过率。当同时修改时间特征和包长特征时，本文方法可以达到 82.1% 的检测绕过率，比黑盒对抗样本高 29.9%。

对比四种特征扰动受限场景下的实验结果，本文可以发现 DNN、SVM 和 IF 等模型更加依赖于时间相关的特征，而 LR 则更加依赖包长相关的特征。

5.6 对抗性流量可视化

为了直观地解释对抗样本逃避恶意加密流量检测模型检测的原因，并且展示对抗样本在具有相似架构的检测模型之间的可转移性，本文进行了以下可视化实验。

5.6.1 对抗样本有效性

对于 CICIDS2017 数据集中每种攻击的恶意流量和背景良性流量，本文提取它们的 77 维统计特征，并在 DNN 代理分类器的指导下为恶意流量生成对抗特征。最后，本文使用 PCA[56] 算法将三组统计特征降为 2 维，并绘制它们对应的散点图，结果如图 5-5 所示。图中蓝色数据点表示良性流量，橙色表示恶意流量，而红色表示对抗样本。从图中观察各类型样本在空间的分布可以看到，对抗样本

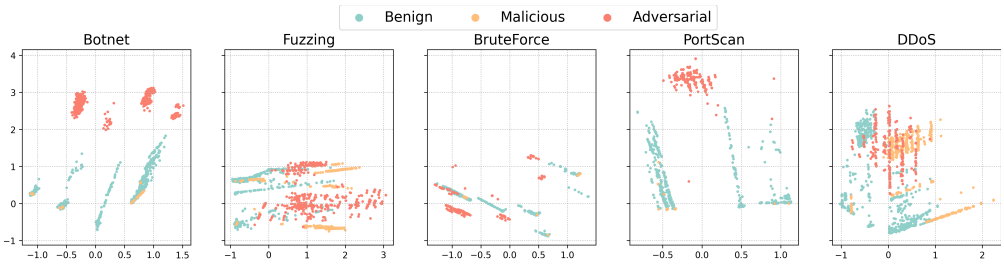


图 5-5 对抗样本攻击有效性

Figure 5-5 Effectiveness of adversarial traffic attack

（红色）在空间上都远离恶意样本（橙色）的位置并且更加接近。这说明经过对抗性扰动的恶意流量样本在空间分布上已经更加接近良性流量样本所在的空间，在分类器的严重更像是“良性”。

5.6.2　对抗样本的可转移性

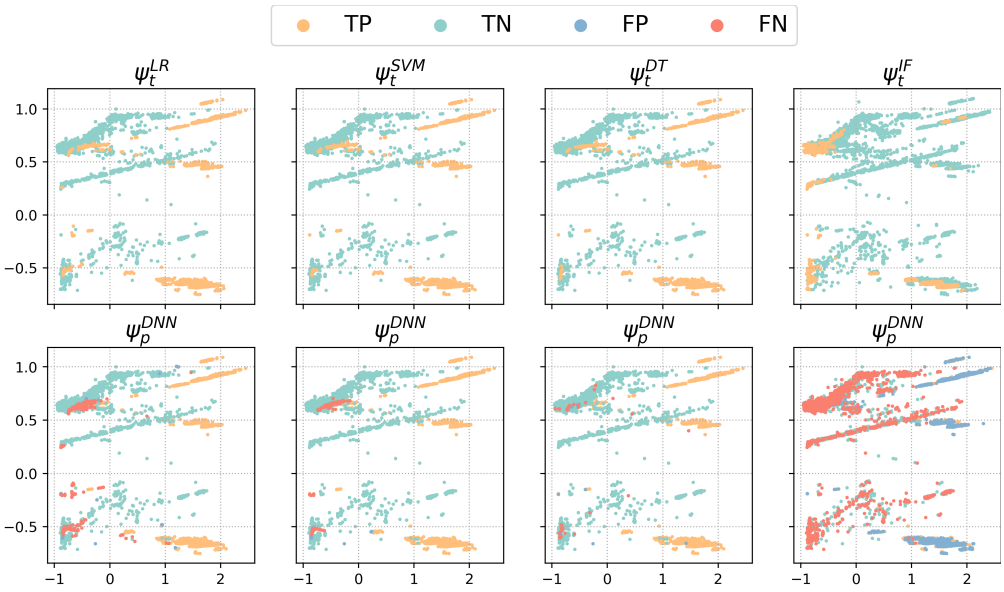


图 5-6 对抗样本可转移性

Figure 5-6 Transferability of adversarial traffic attack

为了展示对抗样本在两个不同架构模型之间的可转移性，本节设计了如下的实验。对于样本 X_i 来说，首先计算目标分类器（以 DNN 为例）的输出结果 $Y_t = \psi_t(X_i)$，再计算代理分类器（以 SVM 为例）的输出结果 $Y_p = \psi_p(X_i)$，最后根据 Y_t 和 Y_p 值的不同将 X_i 分为如表 5-3 所示的四种类别。

最终得到的实验结果如图 5-6 所示。图中 TP（橙色）和 TN（绿色）的样本点越多，说明代理模型和目标模型的预测越接近，而 FP（蓝色）和 FN（红色）的点越多，说明代理模型和目标模型的预测偏差越大。对比四个目标模型，可以发 DNN 作为代理模型的预测更加接近 LR、SVM 和 DT，但是和 IF 的预测偏差较大。可视化的结果与 4-3 中的实验结果所体现的规律是一致的。

表 5-3 流量样本 X_i 分类混淆矩阵

Table 5-3 Confusion matrix for traffic sample X_i

目标模型结果 (Y_t)	代理模型结果 (Y_p)	
	恶意	良性
恶意	True Positive(TP)	False Negative(FN)
良性	False Positive(FP)	True Negative(TN)

5.7 本章小结

本章针对恶意流量检测模型的对抗样本攻击停留在特征层面的问题，提出了基于流量空间的对抗性流量攻击方法。本文针对包长相关的流量特征，提出了流量包长扰动算法；针对时间相关的流量特征，提出了流量时间扰动算法，在这两个算法的基础上实现了从对抗性特征向量到对抗性流量的转化。通过完善的对比实验，将本方法与现有优秀的白盒与黑盒方法进行了对比，实验结果显示了本文所提的方法在仅修改时间特征和包长特征的情况，其检测逃逸率可以达到82.1%，比现有最好的黑盒方法[22]高 29.9%。此外，通过 PCA 算法将高维空间中的样本压缩到二维空间中，直观的展示了对抗样本与普通样本在空间中的分布，解释了对抗样本攻击的原理，此外还通过对比目标模型与代理模型对于同一批数据的预测差别，直观的展示了对抗样本的可转移性。

第 6 章　总结与展望

6.1　总结

本文的目标是研究面向恶意加密流量的对抗样本攻击技术。针对现有恶意加密流量领域的对抗样本攻击研究存在的三个问题，分别提出对应的解决方法，并通过大量的实验验证了每种方法的有效性。

针对现有恶意流量检测模型在面对对抗样本攻击时的脆弱性不完善的问题，本文针对恶意流量检测模型使用的流量特征和检测算法进行脆弱性分析。对于恶意流量检测模型常用的特征，本文使用信息增益和基尼指数评估特征对于分类的重要程度，评估结果总结出一批在不同数据集上都可以良好泛化的特征集合；使用对抗性显著图评估特征的对抗有效性，实验结果显示统计特征对抗有效性较高的特征在一定程度上也是分类重要程度较高的特征，并不随样本发生变化，序列特征中对抗有效性较高的特征主要集中于序列末尾；此外定性的分析了各个特征的对抗难易度，为对抗样本攻击工作做下铺垫。最后通过大量的实验，评估了 3 种神经网络模型和 5 种机器学习模型面对对抗样本攻击时的鲁棒性，实验结果显示在没有经过针对性防御的情况下，基于机器学习的恶意流量检测模型在面对对抗样本攻击时的鲁棒性是不足的。

针对现有白盒与灰盒对抗样本攻击假设攻击者能够获取目标模型的假设不普适的问题，本文提出了基于对抗样本可转移性的黑盒对抗样本攻击。本文提出了能够解释对抗样本可转移性的决策边界理论，提出目标模型决策边界、样本移动方向和样本移动距离是决定对抗样本攻击成功的三个关键因素。基于决策边界理论，本文使用代理模型接近目标模型决策边界，基于黑盒假设生成对抗样本。通过实验探究了代理模型架构、代理模型训练数据、目标模型使用特征和对抗样本扰动幅度是四个决策本方法成功率的关键因素。最终的对抗样本攻击有效性实验证明了本方法攻击未知目标模型的有效性，在代理模型与目标模型架构相似的情况下能够实现 96.2% 以上的检测逃逸率，即便代理模型架构未知，通过提高代理模型的复杂度，也能对低复杂度的目标模型有一定的攻击效果。

针对现有对抗样本攻击大多停留在特征层面，难以转化为有实际流量的问题，本文提出了基于流量扰动对抗性流量翻译方法。针对于包长相关的特征，本文提出流量包长扰动算法，通过包填充和包插入的方式修改流量的时间特征；针对时间相关的特征，本文提出流量时间扰动算法，通过缓冲并延迟发送的方式修改流量的时间特征。最终的对比实验证实本文所提方法的有效性，在仅修改包长特征和时间特征的情况下，本方法的检测逃逸率比最先进的黑盒对抗方法高 29.9%。最后，本文通过 PCA 算法将高维空间中的特征压缩到二维空间，直观的展示了对抗样本在空间中的分布，解释了对抗样本使机器学习模型误分类的原因，并直观的展示了对抗样本的可转移性。

6.2 展望

经过对本文各个研究点的深入分析，对未来的研究工作展望如下。

(1) 提出对目标模型依赖性更小的算法。本文第二个研究点中所提出的黑盒对抗样本生成方法中，需要攻击者收集目标模型的输出作为训练代理模型的训练集。虽然理论上可以通过商业恶意流量检测模型所提供的结果查询接口进行自动化收集，但是收集过程十分耗时并且容易被检测方封禁，难以大规模的收集数据用于训练代理模型。因此未来将研究如何进一步减少对目标模型的依赖，完全绕过目标模型，直接训练代理模型。

(2) 提出复杂特征的流量扰动算法。本文第三个研究点中提出了使用流量扰动的方式将包长相关的特征和时间相关的特征翻译成为具有实际意义的对抗性流量，但是对于需要经过多次计算的复杂特征，简单的流量扰动方式难以精确的修改这些特征。因此在未来的研究工作中将会深入研究如何将更加复杂的流量特征翻译为原始流量，提出更加强大的流量翻译系统。

参考文献

[1] Google. 网络上的 HTTPS 加密 [EB/OL]. 2022. https://transparencyreport.google.com/https/overview.

[2] Cisco. Cisco encrypted traffic analytics white paper [EB/OL]. 2020. https://www.cisco.com/c/en/us/solutions/collateral/enterprise-networks/enterprise-network-security/nb-09-encrytd-traf-anlytcs-wp-cte-en.pdf.

[3] El-Maghraby R T, Abd Elazim N M, Bahaa-Eldin A M. A survey on deep packet inspection [C]//2017 12th International Conference on Computer Engineering and Systems (ICCES). IEEE, 2017: 188-197.

[4] Roesch M, et al. Snort: Lightweight intrusion detection for networks. [C]//Lisa: volume 99. 1999: 229-238.

[5] Marchette D J. A statistical method for profiling network traffic. [C]//Workshop on Intrusion Detection and Network Monitoring. 1999: 119-128.

[6] Crotti M, Gringoli F, Pelosato P, et al. A statistical approach to ip-level classification of network traffic [C]//2006 IEEE International Conference on Communications: volume 1. IEEE, 2006: 170-176.

[7] Papadogiannaki E, Ioannidis S. A survey on encrypted network traffic analysis applications, techniques, and countermeasures [J]. ACM Computing Surveys (CSUR), 2021, 54(6): 1-35.

[8] Wang P, Lin S C, Luo M. A framework for qos-aware traffic classification using semi-supervised machine learning in sdns [C]//2016 IEEE international conference on services computing (SCC). IEEE, 2016: 760-765.

[9] Chen Y, Zang T, Zhang Y, et al. Rethinking encrypted traffic classification: a multi-attribute associated fingerprint approach [C]//2019 IEEE 27th International Conference on Network Protocols (ICNP). IEEE, 2019: 1-11.

[10] Wang Z, Fok K W, Thing V L. Machine learning for encrypted malicious traffic detection: Approaches, datasets and comparative study [J]. Computers & Security, 2022, 113: 102542.

[11] Hodo E, Bellekens X, Hamilton A, et al. Shallow and deep networks intrusion detection system: A taxonomy and survey [J]. arXiv preprint arXiv:1701.02145, 2017.

[12] Wagh S K, Pachghare V K, Kolhe S R. Survey on intrusion detection system using machine learning techniques [J]. International Journal of Computer Applications, 2013, 78(16): 30-37.

[13] Szegedy C, Zaremba W, Sutskever I, et al. Intriguing properties of neural networks [J]. arXiv preprint arXiv:1312.6199, 2013.

[14] Goodfellow I J, Shlens J, Szegedy C. Explaining and harnessing adversarial examples [J]. arXiv preprint arXiv:1412.6572, 2014.

[15] Moosavi-Dezfooli S M, Fawzi A, Frossard P. Deepfool: a simple and accurate method to fool deep neural networks [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2574-2582.

[16] Carlini N, Wagner D. Towards evaluating the robustness of neural networks [C]//2017 ieee symposium on security and privacy (sp). Ieee, 2017: 39-57.

[17] Su J, Vargas D V, Sakurai K. One pixel attack for fooling deep neural networks [J]. IEEE Transactions on Evolutionary Computation, 2019, 23(5): 828-841.

[18] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 1-9.

[19] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition [J]. arXiv preprint arXiv:1409.1556, 2014.

[20] Lin Z, Shi Y, Xue Z. Idsgan: Generative adversarial networks for attack generation against intrusion detection [C]//Advances in Knowledge Discovery and Data Mining: 26th Pacific-Asia Conference, PAKDD 2022, Chengdu, China, May 16–19, 2022, Proceedings, Part III. Springer, 2022: 79-91.

[21] Hashemi M J, Cusack G, Keller E. Towards evaluation of nidss in adversarial setting [C]// Proceedings of the 3rd ACM CoNEXT Workshop on Big DAta, Machine Learning and Artificial Intelligence for Data Communication Networks. 2019: 14-21.

[22] Han D, Wang Z, Zhong Y, et al. Evaluating and improving adversarial robustness of machine learning-based network intrusion detectors [J]. IEEE Journal on Selected Areas in Communications, 2021, 39(8): 2632-2647.

[23] Rojas R, Rojas R. The backpropagation algorithm [J]. Neural networks: a systematic introduction, 1996: 149-182.

[24] Sun G L, Xue Y, Dong Y, et al. An novel hybrid method for effectively classifying encrypted traffic [C]//2010 IEEE Global Telecommunications Conference GLOBECOM 2010. IEEE, 2010: 1-5.

[25] Liu H, Wang Z, Wang Y. Semi-supervised encrypted traffic classification using composite features set [J]. Journal of Networks, 2012, 7(8): 1195.

[26] Anderson B, Paul S, McGrew D. Deciphering malware's use of tls (without decryption) [J]. Journal of Computer Virology and Hacking Techniques, 2018, 14: 195-211.

[27] Liu C, Cao Z, Xiong G, et al. Mampf: Encrypted traffic classification based on multi-attribute markov probability fingerprints [C]//2018 IEEE/ACM 26th International Symposium on Quality of Service (IWQoS). IEEE, 2018: 1-10.

[28] Liu C, He L, Xiong G, et al. Fs-net: A flow sequence network for encrypted traffic classification [C]//IEEE INFOCOM 2019-IEEE Conference On Computer Communications. IEEE, 2019: 1171-1179.

[29] Dey R, Salem F M. Gate-variants of gated recurrent unit (gru) neural networks [C]//2017 IEEE 60th international midwest symposium on circuits and systems (MWSCAS). IEEE, 2017: 1597-1600.

[30] Wang S, Ding Z, Fu Y. Feature selection guided auto-encoder [C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 31. 2017.

[31] Kurakin A, Goodfellow I J, Bengio S. Adversarial examples in the physical world [M]// Artificial intelligence safety and security. Chapman and Hall/CRC, 2018: 99-112.

[32] Papernot N, McDaniel P, Jha S, et al. The limitations of deep learning in adversarial settings [C]//2016 IEEE European symposium on security and privacy (EuroS&P). IEEE, 2016: 372-387.

[33] Papernot N, McDaniel P, Wu X, et al. Distillation as a defense to adversarial perturbations against deep neural networks [C]//2016 IEEE symposium on security and privacy (SP). IEEE, 2016: 582-597.

[34] Chen P Y, Zhang H, Sharma Y, et al. Zoo: Zeroth order optimization based black-box attacks to deep neural networks without training substitute models [C]//Proceedings of the 10th ACM workshop on artificial intelligence and security. 2017: 15-26.

[35] Brendel W, Rauber J, Bethge M. Decision-based adversarial attacks: Reliable attacks against black-box machine learning models [J]. arXiv preprint arXiv:1712.04248, 2017.

[36] Chen S, He Z, Sun C, et al. Universal adversarial attack on attention and the resulting dataset damagenet [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 44(4): 2188-2197.

[37] Kreibich C, Handley M, Paxson V. Network intrusion detection: Evasion, traffic normalization, and end-to-end protocol semantics [C]//Proc. USENIX Security Symposium: volume 2001. 2001.

[38] Cheng T H, Lin Y D, Lai Y C, et al. Evasion techniques: Sneaking through your intrusion detection/prevention systems [J]. IEEE Communications Surveys & Tutorials, 2011, 14(4): 1011-1020.

[39] Yang C, Zhou L, Wen H, et al. U-asg: A universal method to perform adversarial attack on autoencoder based network anomaly detection systems [C]//IEEE INFOCOM 2020-IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS). IEEE, 2020: 68-73.

[40] Kennedy J, Eberhart R. Particle swarm optimization [C]//Proceedings of ICNN'95-international conference on neural networks: volume 4. IEEE, 1995: 1942-1948.

[41] Hearst M A, Dumais S T, Osuna E, et al. Support vector machines [J]. IEEE Intelligent Systems and their applications, 1998, 13(4): 18-28.

[42] Sze V, Chen Y H, Yang T J, et al. Efficient processing of deep neural networks: A tutorial and survey [J]. Proceedings of the IEEE, 2017, 105(12): 2295-2329.

[43] Hochreiter S, Schmidhuber J. Long short-term memory [J]. Neural computation, 1997, 9(8): 1735-1780.

[44] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial networks [J]. Communications of the ACM, 2020, 63(11): 139-144.

[45] Sharafaldin I, Lashkari A H, Ghorbani A A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. [J]. ICISSp, 2018, 1: 108-116.

[46] Malware-Traffic-Analysis.net. Malware traffic analysis [EB/OL]. 2022. https://malware-traffic-analysis.net/.

[47] Abuse. Ssl blacklist project [EB/OL]. 2022. https://sslbl.abuse.ch/.

[48] Wright R E. Logistic regression. [J]. 1995.

[49] Safavian S R, Landgrebe D. A survey of decision tree classifier methodology [J]. IEEE transactions on systems, man, and cybernetics, 1991, 21(3): 660-674.

[50] Liu F T, Ting K M, Zhou Z H. Isolation forest [C]//2008 eighth ieee international conference on data mining. IEEE, 2008: 413-422.

[51] Davis J J, Clark A J. Data preprocessing for anomaly based network intrusion detection: A review [J]. computers & security, 2011, 30(6-7): 353-375.

[52] Moosavi-Dezfooli S M, Fawzi A, Fawzi O, et al. Universal adversarial perturbations [C]// Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1765-1773.

[53] Huawei. Managed threat detection [EB/OL]. 2022. https://www.huaweicloud.com/product/mtd.html.

[54] Amazon. Guardduty [EB/OL]. 2022. https://aws.amazon.com/cn/guardduty/.

[55] Stinson E, Mitchell J C. Towards systematic evaluation of the evadability of bot/botnet detection methods. [J]. WOOT, 2008, 8: 1-9.

[56] Abdi H, Williams L J. Principal component analysis [J]. Wiley interdisciplinary reviews: computational statistics, 2010, 2(4): 433-459.

致 谢

光阴似箭，日月如梭。三年的研究生生涯不知不觉就要结束了！回首在科学院的三年，自己受益良多，期间所取得的每一点进步都离不开老师的谆谆教诲，师兄师姐、同学、朋友的热心帮助和家人的默默支持，谢谢你们！

本文是在导师朱宇佳老师精心指导下完成的，在论文的选题、实验方案的确定、理论分析、数据处理直至论文的撰写和定稿，朱老师都给予了我悉心的指导和无私的帮助，论文完成的整个过程中都渗透着她的心血与汗水。

这几年的研究生生涯，在朱老师的教导下，我的理论知识得以升华，懂得了怎样将自己的理论知识应用于实际，从实际出发重新认识以前学过的知识。朱老师对学生的学习、生活和为人处事等各个方面都给予了无微不至的关心与指导。从老师的身上所学到的不仅是专业技能和知识，还有对待困难的从容和对待工作的执着。老师坦荡高尚的品格给学生树立了做人的楷模，老师开阔的学术思维、严谨的治学态度和勤奋踏实的工作作风，将成为我终生学习的榜样。这在里由衷地感谢朱老师的无私付出。另外还要衷心感谢桑亚飞老师，桑老师在我读研期间为我提供了良好的学习与科研环境，同时在生活中也给予了不少帮助。最后感谢一路走来每一位传授我知识的老师，他们传授的知识是完成这篇论文的基础。

我也要感谢在我身边给予我无私帮助的室友，他们是曹家豪，丁阳，韩健，李志平，孙裴帅，王晗炜，陈宇昕 (按照宿舍号排序)，他们在简单无聊的生活中同我分享了过多的乐趣；还需要感谢同组的同学，他们是贾泽奇，徐家佳，孟茂，杨乐，董润汉，徐红博，暴恒，他们在无数个平凡的日子里陪伴我一起学习与科研；最后还要感谢实验室的师兄师姐，他们是杨济菘，麻景润，黄霁，陈一阁，刘辉，李想，谢江，宋奇格，王炳来，冯备备，吕坤，郭俊成，他们在我需要的时候伸出援手，或帮助我解决了一个又一个问题，或给我提供新的思路。

我还要感谢我勤劳的父母，二十多年来毫无怨言、默默地奉献和培养，才使我走到今天。其实这点点滴滴的成绩都是他们心血与汗水的凝结，无论走到哪里，他们的教诲将永远铭刻在我心。

最后，我要感谢党和国家的培养，才能一步一步走到今天。

2023 年 6 月

作者简历及攻读学位期间发表的学术论文与其他相关学术成果

作者简历：

孙汉武：男，1997 年 6 月 18 日出生，湖北黄冈人，汉族，中国共产党党员。

2016 年 9 月——2020 年 6 月，在北京交通大学计算机与信息技术学院获得学士学位。

2020 年 9 月——2023 年 6 月，在中国科学院信息工程研究所攻读硕士学位。

已发表的学术论文：

Sun H, Peng C, Sang Y, et al. Evading encrypted traffic classifiers by transferable adversarial traffic [C]//Collaborative Computing: Networking, Applications and Worksharing: 18th EAI International Conference, CollaborateCom 2022, Hangzhou, China, October 15-16, 2022, Proceedings, Part II. Springer, 2023: 153-173.

参加的研究项目：

中国科学院战略性先导科技专项: 透明代理服务 (XDC02030400)，2020.09-2023.06

获奖情况：

2020 年，中国科学院大学大学生奖学金